Inteligență Artificială

Reprezentarea cunoștințelor incerte

Slides: Alexandru Sorici

- Cunoștințe Incerte
- Teoria Probabilităților
- Rețele Bayesiene

- În exemplele de probleme de căutare date până acum am presupus *cunoștințe certe* asupra stării curente și acțiuni cu *efect determinist*
- ... dar, în practică, multe situații prezintă necesitatea de a face față incertitudinii

Exemplu de raționament deductiv pe relația *simptom* $\rightarrow$ *problemă*

- dacă simptom=*durere dinți* atunci problemă=*carie*

Raționament greșit (sau, cel puțin, incomplet)

Exemplu de raționament deductiv pe relația *simptom* $\rightarrow$ *problemă*

- dacă simptom=*durere dinți* atunci problemă=*carie*

Raționament greșit (sau, cel puțin, incomplet)

- dacă simptom=*durere dinți* atunci problemă=*abces*
- dacă simptom=*durere dinți* atunci problemă=*boală gingivală*
- ...

Exemplu de raționament deductiv pe relația *simptom* → *problemă*

- dacă simptom=*durere dinți* atunci problemă=*carie*

Raționament greșit (sau, cel puțin, incomplet)

- dacă simptom=*durere dinți* atunci problemă=*abces*
- dacă simptom=*durere dinți* atunci problemă=*boală gingivală*
- . . .

Probleme principiale:

- Este **nefezabil** (chiar imposibil) să completăm lista
- Simpla enumerare a posibilelor cauze nu ne dă informație despre **plauzibilitatea (likelihood) lor relativă**
- O relație **cauzală** de tip *problemă=abces* → *simptom=durere dinți* **nu** este tot timpul adevărată

Necesitatea surprinderii (modelării) incertitudinii apare din cauza:

- Imposibilității sau lipsei de fezabilitate a enumerării regulilor de inferență
- Ignoranței la nivel teoretic: nu există suficiente cunoștințe pentru a scrie reguli de inferență corecte
- Ignoranței la nivel practic: chiar dacă avem reguli de inferență *definite exhaustiv*, ne lipsește informația necesară aplicării lor

Adevăr, Falsitate, Încredere (Belief)

- Teoria Probabilităților permite asignarea unui **grad numeric de certitudine** (valoare $\in [0, 1]$) unei afirmații (care poate fi **adevarată** sau **falsă**)
  - Atenție: **grad de certitudine** $\neq$ **grad de adevăr** (noțiune utilizată, de exemplu, în Logica Fuzzy)
- Teoria Probabilităților permite modelarea incertitudinii cauzate de **dificultatea enumerării** sau de **lipsa teoretică/practică de cunoștințe**

- Probabilitatea unui eveniment incert este măsura **gradului de încredere** sau **plauzabilitatea** producerii unui eveniment.
- Gradul de încredere se poate modifica prin **obținerea de probe** (evidence)

- Probabilitate necondiționată (apriori) – denotă un grad de încredere **înaintea** obținerii probe pentru o ipoteză / un eveniment
- Probabilitate condiționată (aposteriori) – denotă un grad de încredere actualizat **în urma obținerii** unor probe pentru o ipoteză / un eveniment

- Pentru a defini **evenimente** vom lucra cu variabile aleatoare
- Variabilele aleatoare asignează fiecărui **eveniment elementar** / **atomic** o valoare $\in [0, 1]$.
- Variabilele aleatoare (și evenimentele atomice pe care le denotă) pot avea **domenii de definiție** care pot fi:
  - booleene: e.g. plouă / nu plouă
  - discrete: e.g. cele șase fețe ce pot rezulta din aruncarea unui zar
  - continue: e.g. viteza moleculelor de gaz dintr-un recipient

Modul în care se atribuie **valori de probabilitate** unui eveniment poate fi privit din diferite perspective:

- Perspectivă frecventistă: valorile de probabilitate vin din **măsuratori** (e.g. incidența unei boli într-o țară se obține ca medie peste ani a procentului de pacienți internați cu acea boală în spitale)
- Perspectivă obiectivistă: incertitudinea (și valoarea de probabilitate care o cuantifică) este o "**proprietate** a universului" pe care o descoperim prin măsurători (e.g. fenomene cuantice)
- Perspectiva subiectivistă: valorile de probabilitate vin din "**gradele de încredere**" acordate de un agent rațional (e.g. șansele de a lua un interview)

- Evenimente mutual exclusive: nu pot fi simultan adevărate. Exemple:
  - Aruncarea unei monede: cade cap / pajură
  - Aruncarea unui zar: fețele 1, 2, 3 sunt mutual exclusive
- Evenimente mutual exhaustive: enumerarea lor acoperă tot spațiul posibilităților pentru situația/procesul în cauză. Exemple:
  - Aruncarea unei monede: cap / pajură
  - Aruncarea unui zar: obținerea fețelor 1,2,3,4,5,6 sunt evenimente mutual exhaustive

- $P(X = x)$ – gradul de încredere (**probabilitatea**) ca **variabila aleatoare** X (scris cu majusculă) să aibă **valoarea** x (scris cu literă mică)
  - Vom folosi notația $P(X)$ pentru a denota **distribuția de probabilitate** a variabilei X (i.e. $P(X = x_1), P(X = x_2), \ldots, P(X = x_n)$ pentru toate valorile $x_1, x_2, \ldots, x_n$ pe care le-ar putea avea variabila X)

- Pentru cazul variabilelor de tip eveniment binar (cu doar două valori: *adevărat* sau *fals*), folosim următoarea prescurtare a notației:
  - $P(X = adev) = P(x)$
  - $P(X = fals) = P(\neg x)$

O funcție $P : S \to \mathbb{R}$ este o **măsură de probabilitate** (unde S este un *spațiu de probabilitate*) dacă satisface axiomele:

- $0 \leq P(X = x) \leq 1$
- $P(S) = 1$ (sau $P(adev) = 1$, $P(fals) = 0$)
- $P(X = x \vee Y = y) = P(X = x) + P(Y = y) - P(X = x \wedge Y = y)$

Din axiome rezultă:

$$P(x \vee \neg x) = P(adev) = P(x) + P(\neg x) - P(x \wedge \neg x) = P(x) + P(\neg x) - P(fals)$$
$$\Rightarrow P(x) = 1 - P(\neg x)$$

regula probabilității complementare

Distribuția **comună** a unor evenimente (joint probability distribution)

Exemplu:

- Fie variabila aleatoare binară *Gripa* cu valori $\{adev, fals\}$ și variabila aleatoare *Tuse* cu valori $\{absenta, usoara, grava\}$
- Distribuția **comună** ($P(Gripa \wedge Tuse) = P(Gripa, Tuse)$) a celor două variabile aleatoare se poate reprezenta sub forma unei tabele:

	absenta	usoara	grava
adev	0.05	0.20	0.15
fals	0.4	0.12	0.08

Pentru evenimente $e_1, e_2, \ldots, e_n$ mutual exclusive:

$$P(e_1 \vee e_2 \vee \ldots \vee e_n) = P(e_1) + P(e_2) + \ldots + P(e_n)$$

Formula **probabilității totale** (a **marginalizării**): fie $e(A)$ – mulțimea de evenimente atomice **mutual exclusive și exhaustive** în care apare evenimentul A.

$$P(A) = \sum_{e_i \in e(A)} P(e_i)$$

Exemplu: fie evenimentele din distribuția comună $P(Gripa, Febra)$:
$\{(gripa \wedge febra), (gripa \wedge \neg febra), (\neg gripa \wedge febra), (\neg gripa \wedge \neg febra)\}$

$$P(gripa) = P(gripa \wedge febra) + P(gripa \wedge \neg febra) = \sum_{F \in \{febra, \neg febra\}} P(gripa \wedge F)$$

$$P(\neg gripa) = P(\neg gripa \wedge febra) + P(\neg gripa \wedge \neg febra) = \sum_{F \in \{febra, \neg febra\}} P(\neg gripa \wedge F)$$

Regula produsului

- Se aplică în cadrul probabilităților **condiționate**.
- Probabilitatea de producere a evenimentului A, **în condițiile** producerii evenimentului B se notează ca $P(A|B)$

$$P(A|B) = \frac{P(A \wedge B)}{P(B)}$$
$$\Rightarrow P(A \wedge B) = P(A|B) \cdot P(B) = P(B|A) \cdot P(A)$$

Regula probabilității totale și **regula produsului** pot fi combinate:

În exemplul de gripă și febră putem scrie:

$$P(gripa) = P(gripa|febra) \cdot P(febra) + P(gripa|\neg febra) \cdot P(\neg febra)$$

Pe caz general, dacă un eveniment Y se poate descompune în n evenimente atomice $Y_1, Y_2, \ldots, Y_n$ **mutual exclusive și exhaustive**, atunci pentru orice eveniment X este adevărată identitatea (regula probabilității totale):

$$\mathbf{P(X)} = \sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{P(X \wedge Y_i)} = \sum_{\mathbf{i=1}}^{\mathbf{n}} \mathbf{P(X|Y_i) \cdot P(Y_i)}$$

O aplicare uzuală a acestei reguli este pentru descompunerea evenimentelor binare Y ($\{Y_1 = true, Y_2 = false\}$) în:

$$\mathbf{P(X)} = \mathbf{P(X|y) \cdot P(y) + P(X|\neg y) \cdot P(\neg y)}$$

unde am folosit notația pe scurt y și $\neg y$ pentru a desemna $Y_1 = true$ și $Y_2 = false$, respectiv.

Folosirea distribuției comune pentru inferențe

- Dacă se cunoaște distribuția de probabilitate comună a tuturor variabilelor aleatoare ce descriu o stare a problemei, se poate răspunde oricărei interogări probabilistice

Exemplu:

	dp		$\neg dp$	
	tm	$\neg tm$	tm	$\neg tm$
bi	0.09	0.05	0.07	0.01
$\neg bi$	0.02	0.08	0.03	0.65

Unde DP = durere în piept, TM = tensiune arterială mare, BI=boală de inimă

$$
\begin{aligned}
P(bi \vee dp) =& P(bi) + P(dp) - P(bi \wedge dp) = \\
=& P(bi \wedge dp \wedge tm) + P(bi \wedge dp \wedge \neg tm) + P(bi \wedge \neg dp \wedge tm) + P(bi \wedge \neg dp \wedge \neg tm) + \\
& P(bi \wedge dp \wedge tm) + P(\neg bi \wedge dp \wedge tm) + P(bi \wedge dp \wedge \neg tm) + P(\neg bi \wedge dp \wedge \neg tm) - \\
& (P(bi \wedge dp \wedge tm) + P(bi \wedge dp \wedge \neg tm)) \\
=& 0.07 + 0.01 + 0.09 + 0.02 + 0.05 + 0.08 = 0.32
\end{aligned}
$$

De obicei vom dori calcularea unei **probabilități condiționate** a unei variabile date fiind **probe**:

$$P(bi|tm) = \frac{P(bi \wedge tm)}{P(tm)} = \frac{\sum_{DP} P(bi \wedge tm \wedge DP)}{\sum_{BI,DP} P(tm \wedge BI \wedge DP)} = \frac{0.09 + 0.07}{0.09 + 0.07 + 0.02 + 0.03} = 0.76$$

sau

$$P(\underbrace{\neg bi}_{\text{(Q)uery}} \mid \underbrace{tm}_{\text{(E)vidence}}) = \frac{P(\neg bi \wedge tm)}{P(tm)} = \underbrace{\frac{\overbrace{\sum_{DP}}^{\text{(U)nobserved}} P(\neg bi \wedge tm \wedge DP)}{\sum_{BI,DP} P(tm \wedge BI \wedge DP)}}_{\text{normali(Z)er}} = \frac{0.02 + 0.03}{0.09 + 0.07 + 0.02 + 0.03} = 0.24$$

În exemplul anterior putem observa că $\alpha = \frac{1}{P(TM)}$ este constant și acționează ca un **factor de normalizare**, ce face ca probabilități relevante să însumeze 1.

Astfel, un artificiu de calcul ne poate scuti de explicitarea factorului de normalizare:

$$P(bi|tm) = \alpha \cdot P(bi \wedge tm) = \alpha(0.09 + 0.07)$$
$$P(\neg bi|tm) = \alpha \cdot P(\neg bi \wedge tm) = \alpha(0.02 + 0.03)$$

Știm că $P(bi|tm) + P(\neg bi|tm) = 1$, așadar:

$$\alpha = \frac{1}{0.09 + 0.07 + 0.02 + 0.03}$$

Procedura generală de inferență:

$$P(Q|E_1, E_2, \ldots) = \frac{1}{Z} P(Q \wedge E_1 \wedge E_2, \ldots) = \frac{1}{Z} \sum_{U_1, U_2, \ldots} P(Q \wedge E_1 \wedge E_2 \wedge \ldots \wedge U_1 \wedge U_2 \wedge \ldots)$$

unde:

- Q – **variabila** aleatoare interogată
- E – **mulțimea de probe** (variabile aleatoare a căror valoare se cunoaște cu certitudine)
- U – **mulțimea de variabile aleatoare neobservate** (care împreună cu Q și E constituie evenimente mutual exclusive și exhaustive)
- $1/Z$ – **factor de normalizare** al distribuției

Procedura generală de inferență poate fi *intractabilă computațional*:

- Pentru n variabile aleatoare booleene tabela distribuției de probabilitate comună are 2^n intrări
- Cost computațional în timp și spațiu: $O(2^n)$
- Pe caz de variabile discrete cu mai mult de 2 valori, situația se complică și mai mult

În exemplul de analiză al bolii de inimă, presupunem că am mai considera rezultatul meciului FCSB-Dinamo cu valori posibile $RM = \{fcsb, dinamo, remiza\}$.
Atunci am avea:

$$P(BI, TM, DP, RM) = P(BI|RM, TM, DP) \cdot P(RM, TM, DP)$$

Dar, dacă presupunem că rezultatul unui meci nu influențează starea de sănătate a unui pacient, atunci $P(BI|RM, TM, DP) = P(BI|TM, DP)$.

$\Rightarrow$ reducem un tabel de distribuție comună de probabilitate de $2 \times 2 \times 2 \times 3 = 24$ de valori la două tabele de 3 (RM) + 8 (BI, DP, TM) = 11 valori.

Independență condițională

- Știm că $P(A|B) = P(A \wedge B)/P(B)$
- Insă, spunem că evenimentul A este **independent** de evenimentul B dacă: $P(A|B) = P(A)$
- În caz că A și B sunt independente: $P(A \wedge B) = P(A) \cdot P(B)$

- Evenimentele A si B sunt **independente condițional** fiind dat un eveniment C dacă:
  - Știind că C apare, apariția lui A nu influențează apariția lui B și apariția lui B nu influențează apariția lui A
  - $\mathbf{P(A|C) = P(A|B, C)}$
  - $\mathbf{P(A, B|C) = P(A|C) \cdot P(B|C)}$

Știm că:

$$P(X, Y) = P(X|Y) \cdot P(Y)$$
$$P(X, Y) = P(Y|X) \cdot P(X)$$

astfel că:

$$\mathbf{P(X|Y)} = \frac{\mathbf{P(Y|X)} \cdot \mathbf{P(X)}}{\mathbf{P(Y)}}$$ – Teorema lui Bayes

Interpretat cel mai des ca:

$$\mathbf{P(Hypothesis|Evidence)} = \frac{\mathbf{P(Evidence|Hypothesis)} \cdot \mathbf{P(Hypothesis)}}{\mathbf{P(Evidence)}}$$
$$\mathbf{APosteriori} = \frac{\mathbf{Plauzabilitate} \cdot \mathbf{APriori}}{\mathbf{Probe}}$$

Exemplu utilizare Bayes: considerăm o formă de gripă ce afectează 1% din populație și un test care indică prezența bolii cu o anumită certitudine.

$$P(gripa) = 0.01$$
$$P(Test = +|gripa) = 0.9$$
$$P(Test = +|\neg gripa) = 0.2$$

Care este probabilitatea $P(gripa|Test = +)$?

Exemplu utilizare Bayes: considerăm o formă de gripă ce afectează 1% din populație și un test care indică prezența bolii cu o anumită certitudine.

$$P(gripa) = 0.01$$
$$P(Test = +|gripa) = 0.9$$
$$P(Test = +|\neg gripa) = 0.2$$

Care este probabilitatea $P(gripa|Test = +)$?
Folosind Bayes:

$$\begin{aligned} P(gripa|Test = +) &= \frac{P(Test = +|gripa) \cdot P(gripa)}{P(Test = +)} \\ &= \frac{P(Test = +|gripa) \cdot P(gripa)}{P(Test = +|gripa) \cdot P(gripa) + P(Test = +|\neg gripa) \cdot P(\neg gripa)} \\ &= \frac{0.9 \cdot 0.01}{0.9 \cdot 0.01 + 0.2 \cdot 0.99} \approx 0.043 \end{aligned}$$

Generalizare Teoremă Bayes la mai multe ipoteze

- Fie $h_1, h_2, \ldots, h_k$ ipoteze posibile pentru probele e
- Dacă h_i **mutual exclusive și exhaustive**, $i = 1, k$

$$\mathbf{P(h_i|e)} = \frac{\mathbf{P(e|h_i)} \cdot \mathbf{P(h_i)}}{\sum_{\mathbf{j=1}}^{\mathbf{k}} \mathbf{P(e|h_j)} \cdot \mathbf{P(h_j)}}$$

Generalizare Teoremă Bayes la mai multe ipoteze și mai multe probe

- Fie $h_1, h_2, \ldots, h_k$ ipoteze posibile pentru probele $e_1, e_2, \ldots, e_n$
- Dacă h_i **mutual exclusive și exhaustive**, $i = 1, k$

$$\mathbf{P(h_i|e_1, e_2, \ldots, e_n) = \frac{P(e_1, e_2, \ldots, e_n|h_i) \cdot P(h_i)}{\sum_{j=1}^{k} P(e_1, e_2, \ldots, e_n|h_j) \cdot P(h_j)}}$$

- Dacă evenimentele probă sunt **independente condițional dat fiind** h_i, atunci:
- $P(e_1, e_2, \ldots, e_n|h_i) = ?$

Generalizare Teoremă Bayes la mai multe ipoteze și mai multe probe

- Fie $h_1, h_2, \ldots, h_k$ ipoteze posibile pentru probele $e_1, e_2, \ldots, e_n$
- Dacă h_i **mutual exclusive și exhaustive**, $i = 1, k$

$$\mathbf{P(h_i|e_1, e_2, \ldots, e_n) = \frac{P(e_1, e_2, \ldots, e_n|h_i) \cdot P(h_i)}{\sum_{j=1}^{k} P(e_1, e_2, \ldots, e_n|h_j) \cdot P(h_j)}}$$

- Dacă evenimentele probă sunt **independente condițional dat fiind** h_i, atunci:
- $P(e_1, e_2, \ldots, e_n|h_i) = P(e_1|h_i) \cdot P(e_2|h_i) \cdot \ldots \cdot P(e_n|h_i)$

Modelul **Naive Bayes**

- Independența condițională între evenimente probă este deseori **presupusă**, chiar și când nu ține de fapt.
- $P(Cauza, E_1, E_2, \dots E_n) = P(Cauza) \cdot \prod_{i=1}^{n} P(E_i|Cauza)$
- $P(Cauza|E_1, E_2, \dots E_n) = \alpha \cdot P(Cauza) \cdot \prod_{i=1}^{n} P(E_i|Cauza)$, unde $\alpha = \frac{1}{P(E_1, E_2, \dots, E_n)}$

Cauza Maximum APosteriori

$$Cauza_{MAP} = \arg\max_j P(Cauza_j) \cdot \prod_i^n P(E_i|Cauza_j)$$

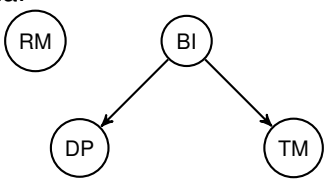
Rețele Bayesiene : Definiții

Rețele Bayesiene : Definiții

Rețele Bayesiene

- Reprezintă explicit relațiile de **dependența cauzală** între variabile aleatoare sub forma unui **graf orientat aciclic (DAG)**
- Specifică distribuțiile de probabilitate
  - **apriori**: pentru variabile necondiționate
  - **probabilități condiționate**: pentru variabilele condiționate de una sau mai multe variabile părinte
- Informația despre relațiile de dependență între variabile ajută la simplificarea procedurilor de inferență probabilistică

Exemplul cu analiza bolii de inimă:

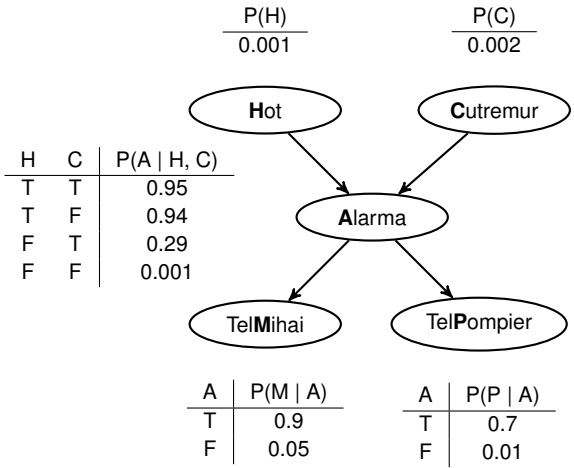


Rețele Bayesiene : Definiții

- Fiecare **nod** dintr-o rețea Bayesiana este o **variabilă aleatoare**
- Legăturile orientate $\mathbf{X} \rightarrow \mathbf{Y}$ denotă că variabila X are of influență directă asupra variabilei Y. Notăm prin **parinti**($\mathbf{Y}$) mulțimea de variabile care influențează direct variabila Y. Mulțimea *parinti*(Y) poate fi si vidă.
- Fiecare nod are asociată o distribuție de probabilități condiționate ce cuantifică $\mathbf{P}(\mathbf{X_i}|\textbf{parinti}(\mathbf{X_i}))$
  - Pentru variabile aleatoare boolene sau discrete, distribuția ia forma unor **tabele de probabilitați condiționate** (CPT)

Rețele Bayesiene : Definiții

Structură rețea Bayesiană



Pentru că variabilele aleatoare din exemplu sunt **binare**, tabela de probabilități condiționate pentru $P(A|H, C)$ este:

H	**C**	**P(A | H, C)**	
		T	F
T	T	0.95	0.05
T	F	0.94	0.06
F	T	0.29	0.71
F	F	0.001	0.999

Rețele Bayesiene : Structură

Structura unei rețele bayesiene ajută la:

- Reprezentarea distribuției de probabilitate a mai multor variabile aleatoare
- Specificarea independenței condiționale – construcția rețelei
- **Factorizarea** distribuției **comune** de probabilitate a variabilelor aleatoare

$$P(X_1, X_2, \ldots, X_n) = \prod_{i=1}^{n} P(X_i | parinti(X_i))$$

Rețele Bayesiene : Structură

Cum construim o rețea a.î. distribuția de probabilități condiționate să fie o bună reprezentare a problemei / situației modelate?

Rețele Bayesiene : Structură

Cum construim o rețea a.î. distribuția de probabilități condiționate să fie o bună reprezentare a problemei / situației modelate?

Din **regula produsului** de probabilități aplicată pe n noduri dintr-o rețea bayesiană avem:

$$\begin{aligned} P(X_1, X_2, \ldots, X_n) &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}, X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)P(X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)\ldots P(X_1) = \prod_{i=1}^{n} P(X_i|X_{i-1}\ldots X_1) \end{aligned}$$

Rețele Bayesiene : Structură

Cum construim o rețea a.î. distribuția de probabilități condiționate să fie o bună reprezentare a problemei / situației modelate?

Din **regula produsului** de probabilități aplicată pe n noduri dintr-o rețea bayesiană avem:

$$\begin{aligned} P(X_1, X_2, \ldots, X_n) &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}, X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)P(X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)\ldots P(X_1) = \prod_{i=1}^{n} P(X_i|X_{i-1}\ldots X_1) \end{aligned}$$

Comparând ecuația de mai sus cu **factorizarea** unei rețele Bayesiene, observăm că într-o RB **facem presupunerea că**:

$$P(X_i|X_{i-1}, \ldots, X_1) = P(X_i|parinti(X_i))$$

pentru fiecare nod X_i, presupunând că $parinti(X_i) \subseteq \{X_{i-1}, \ldots, X_1\}$

Rețele Bayesiene : Structură

- În construirea unei RB, asigurăm o reprezentare corectă a domeniului **cu condiția ca** fiecare nod să fie independent condițional de nondescendenți, fiind dați părinții săi.
- Condiția aceasta poate fi satisfăcută dacă etichetăm nodurile într-o ordine consistentă cu DAG (graf orientat aciclic).
- Astfel, în general, **cauzele preced direct efectul**: părinții unui nod X_i trebuie să fie toate acele noduri $(X_{i-1}, \ldots, X_{i-k})$ care **influențează direct** X_i

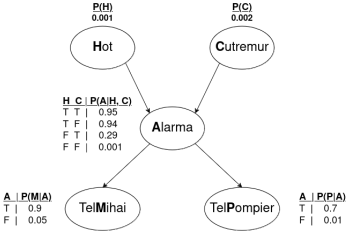
Pași construire RB:

1. Alegere **mulțime variabile aleatoare** care descriu problema
2. Alegere **ordonare** a acestor variabile (conform influenței cauzale)
3. **Cât timp** mai sunt variabile **repetă**:
   a. Alegere variabilă X_i și adaugare nod corespunzător în RB
   b. Atribuire $parinti(X_i) \leftarrow$ set minim de noduri deja existente în rețea, a.î. proprietatea de independență condițională este satisfăcută
   c. Definire tabelă de probabilități condiționate pentru X_i

Deoarece fiecare nod este legat numai la noduri anterioare $\rightarrow$ DAG

Rețele Bayesiene : Proprietăți

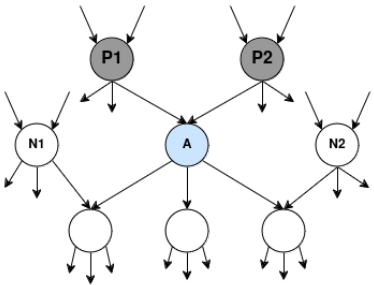
- O RB are o **reprezentare structurată local** – fiecare componentă a structurii interacționează cu un număr limitat de alte componente
  - De exemplu, din n variabile aleatoare boolene ale unei RB, putem presupune că numărul maxim de părinți al unei variabile este k
  - $\Rightarrow n \times 2^k$ numere necesare pentru a specifica o distribuție completă de probabilități, în loc de 2^n
  - Exemplu: pentru n=30 și k=5, diferența este între $2^5 \times 30 = 960$ vs. 2^{30} valori necesare



În exemplul problemei cu alarma (variabile aleatoare boolene):

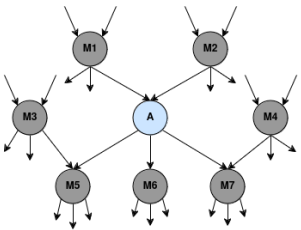
- În lipsa structurii de dependență condiționată: $P(H, C, A, M, P)$ are nevoie de o tabelă cu $2^5 = 32$ intrări
- În RB dată $P(H, C, A, M, P) = P(H) \cdot P(C) \cdot P(A|H, C) \cdot P(M|A) \cdot P(P|A)$ - 5 factori necesitând $1 + 1 + 4 + 2 + 2 = 10$ valori specificate în tabelele de probabilități condiționate

Rețele Bayesiene : Proprietăți



Într-o RB, un nod A este **condițional independent** de non-descendenți (e.g. N_1, N_2), dați fiind părinții săi (P_1, P_2)

Pătura Markov



Într-o RB, un nod *A* este **condițional independent** de orice alt nod din rețea, dați fiind:

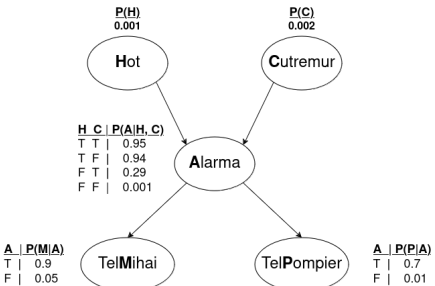
- părinții săi (M_1, M_2)
- copii săi (M_5, M_6, M_7)
- părinții copiilor săi ($M3$, $M4$)

O rețea Bayesiană descrie **distribuția comună completă**. Ca atare:

$$P(Q, setE, setU) = \prod_{i=1}^{n} P(X_i | parinti(X_i))$$

unde: Q – variabilă interogată, $setE$ – set de variabile probă, $setU$ – set de variabile neobservate. Astfel, inferența pe caz general se exprimă ca:

$$P(Q|setE) = \frac{1}{Z} P(Q \wedge setE) = \frac{1}{Z} \sum_{setU} \prod_{i=1}^{n} P(X_i | parinti(X_i))$$



Calculam $P(h|m, \neg p)$, unde $Q = H$, $setE = \{m, \neg p\}$ și $setU = \{C, A\}$

$$P(h|m,\neg p) = \frac{P(h,m,\neg p)}{P(m,\neg p)} = \frac{\sum\limits_{A,C} P(h,m,\neg p,A,C)}{\sum\limits_{A,C,H} P(m,\neg p,H,A,C)} = \frac{\sum\limits_{A,C} P(h)\cdot P(C)\cdot P(a|h,C)\cdot P(m|A)\cdot P(\neg p|A)}{\sum\limits_{A,C,H} P(H)\cdot P(C)\cdot P(a|H,C)\cdot P(m|A)\cdot P(\neg p|A)}$$

Data viitoare:

- Metodă automată de **inferență exactă**
- Metode de **inferență aproximativă** prin **tehnici de eșantionare**

Mulțumesc!



https://forms.gle/DJUdkejstkvyNRF5A

Feedbackul este binevenit!