Inteligență Artificială

Inferență în Rețele Bayesiene

Credits: Alexandru Sorici
CMU AI http://ai.berkeley.edu

- Rețele Bayesiene
- Independență
- Enumerare
- Eliminare

Independență condițională – Recapitulare

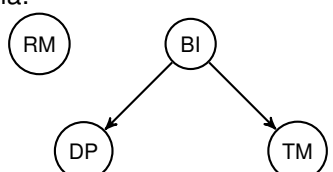
- Evenimentele *A* si *B* sunt **independente condițional** fiind dat un eveniment *C* dacă:
  - Știind că C apare, apariția lui A nu influențează apariția lui B și apariția lui B nu influențează apariția lui A
  - $\mathbf{P}(\mathbf{A}|\mathbf{C}) = \mathbf{P}(\mathbf{A}|\mathbf{B},\mathbf{C})$
  - $\mathbf{P}(\mathbf{A},\mathbf{B}|\mathbf{C}) = \mathbf{P}(\mathbf{A}|\mathbf{C}) \cdot \mathbf{P}(\mathbf{B}|\mathbf{C})$

Rețele Bayesiene

Rețele Bayesiene

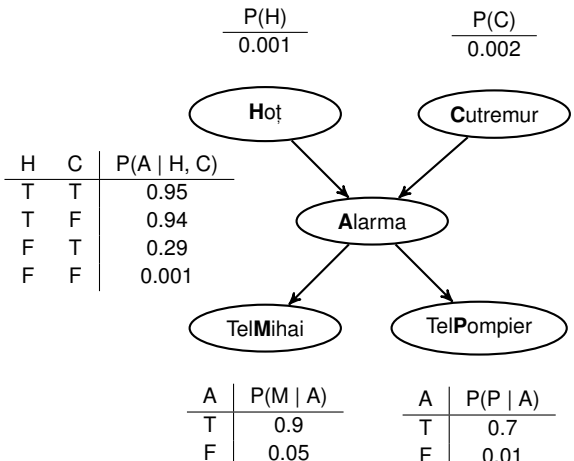
- Reprezintă explicit relațiile de **dependența cauzală** între variabile aleatoare sub forma unui **graf orientat aciclic (DAG)**
- Specifică distribuțiile de probabilitate
  - **apriori**: pentru variabile necondiționate
  - **probabilități condiționate**: pentru variabilele condiționate de una sau mai multe variabile părinte
- Informația despre relațiile de dependență între variabile ajută la simplificarea procedurilor de inferență probabilistică

Exemplul cu analiza bolii de inimă:



- Fiecare **nod** dintr-o rețea Bayesiana este o **variabilă aleatoare**
- Legăturile orientate $\mathbf{X} \rightarrow \mathbf{Y}$ denotă că variabila X are of influență directă asupra variabilei Y. Notăm prin **parinti**($\mathbf{Y}$) mulțimea de variabile care influențează direct variabila Y. Mulțimea *parinti*(Y) poate fi si vidă.
- Fiecare nod are asociată o distribuție de probabilități condiționate ce cuantifică $\mathbf{P}(\mathbf{X_i}|\mathbf{parinti}(\mathbf{X_i}))$
  - Pentru variabile aleatoare boolene sau discrete, distribuția ia forma unor **tabele de probabilitați condiționate** (CPT)

Structură rețea Bayesiană



Pentru că variabilele aleatoare din exemplu sunt **binare**, tabela de probabilități condiționate pentru $P(A|H,C)$ este:

H	**C**	**P(A | H, C)**	
		T	F
T	T	0.95	0.05
T	F	0.94	0.06
F	T	0.29	0.71
F	F	0.001	0.999

Structura unei rețele bayesiene ajută la:

- Reprezentarea distribuției de probabilitate a mai multor variabile aleatoare
- Specificarea independenței condiționale – construcția rețelei
- **Factorizarea** distribuției **comune** de probabilitate a variabilelor aleatoare

$$P(X_1, X_2, \ldots, X_n) = \prod_{i=1}^{n} P(X_i | parinti(X_i))$$

Cum construim o rețea a.î. distribuția de probabilități condiționate să fie o bună reprezentare a problemei / situației modelate?

Cum construim o rețea a.î. distribuția de probabilități condiționate să fie o bună reprezentare a problemei / situației modelate?

Din **regula produsului** de probabilități aplicată pe n noduri dintr-o rețea bayesiană avem:

$$\begin{aligned} P(X_1, X_2, \ldots, X_n) &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}, X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)P(X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)\ldots P(X_1) = \prod_{i=1}^{n} P(X_i|X_{i-1}\ldots X_1) \end{aligned}$$

Cum construim o rețea a.î. distribuția de probabilități condiționate să fie o bună reprezentare a problemei / situației modelate?

Din **regula produsului** de probabilități aplicată pe n noduri dintr-o rețea bayesiană avem:

$$\begin{aligned} P(X_1, X_2, \ldots, X_n) &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}, X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)P(X_{n-2}, \ldots, X_1) \\ &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)\ldots P(X_1) = \prod_{i=1}^{n} P(X_i|X_{i-1}\ldots X_1) \end{aligned}$$

Comparând ecuația de mai sus cu **factorizarea** unei rețele Bayesiene, observăm că într-o RB **facem presupunerea că**:

$$P(X_i|X_{i-1}, \ldots, X_1) = P(X_i|parinti(X_i))$$

pentru fiecare nod X_i, presupunând că $parinti(X_i) \subseteq \{X_{i-1}, \ldots, X_1\}$

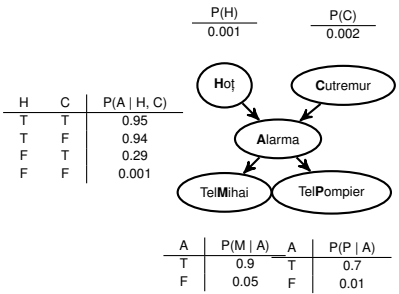
- În construirea unei RB, asigurăm o reprezentare corectă a domeniului **cu condiția ca** fiecare nod să fie independent condițional de nondescendenți, fiind dați părinții săi.
- Condiția aceasta poate fi satisfăcută dacă etichetăm nodurile într-o ordine consistentă cu DAG (graf orientat aciclic).
- Astfel, în general, **cauzele preced direct efectul**: părinții unui nod X_i trebuie să fie toate acele noduri $(X_{i-1}, \ldots, X_{i-k})$ care **influențează direct** X_i

Pași construire RB:

1. Alegere **mulțime variabile aleatoare** care descriu problema
2. Alegere **ordonare** a acestor variabile (conform influenței cauzale)
3. **Cât timp** mai sunt variabile **repetă**:
   a. Alegere variabilă X_i și adaugare nod corespunzător în RB
   b. Atribuire $parinti(X_i) \leftarrow$ set minim de noduri deja existente în rețea, a.î. proprietatea de independență condițională este satisfăcută
   c. Definire tabelă de probabilități condiționate pentru X_i

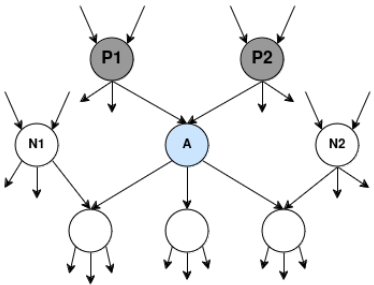
Deoarece fiecare nod este legat numai la noduri anterioare $\rightarrow$ DAG

- O RB are o **reprezentare structurată local** – fiecare componentă a structurii interacționează cu un număr limitat de alte componente
  - De exemplu, din n variabile aleatoare boolene ale unei RB, putem presupune că numărul maxim de părinți al unei variabile este k
  - $\Rightarrow n \times 2^k$ numere necesare pentru a specifica o distribuție completă de probabilități, în loc de 2^n
  - Exemplu: pentru n=30 și k=5, diferența este între $2^5 \times 30 = 960$ vs. 2^{30} valori necesare



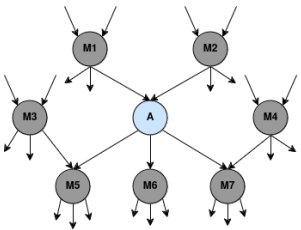
În exemplul problemei cu alarma (variabile aleatoare boolene):

- În lipsa structurii de dependență condiționată: $P(H, C, A, M, P)$ are nevoie de o tabelă cu $2^5 = 32$ intrări
- În RB dată $P(H, C, A, M, P) = P(H) \cdot P(C) \cdot P(A|H, C) \cdot P(M|A) \cdot P(P|A)$ - 5 factori necesitând $1 + 1 + 4 + 2 + 2 = 10$ valori specificate în tabelele de probabilități condiționate



Într-o RB, un nod A este **condițional independent** de non-descendenți (e.g. N_1, N_2), dați fiind părinții săi (P_1, P_2)

Pătura Markov



Într-o RB, un nod A este **condițional independent** de orice alt nod din rețea, dați fiind:

- părinții săi (M_1, M_2)
- copii săi (M_5, M_6, M_7)
- părinții copiilor săi ($M3$, $M4$)

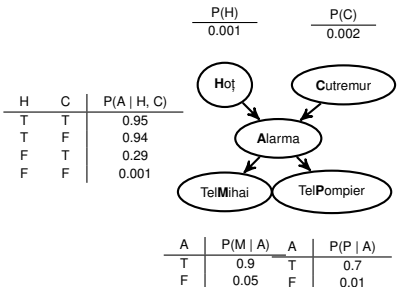
O rețea Bayesiană descrie **distribuția comună completă**. Ca atare:

$$P(Q, setE, setU) = \prod_{i=1}^{n} P(X_i | parinti(X_i))$$

unde: Q – variabilă interogată, $setE$ – set de variabile probă, $setU$ – set de variabile neobservate. Astfel, inferența pe caz general se exprimă ca:

$$P(Q|setE) = \frac{1}{Z} P(Q \wedge setE) = \frac{1}{Z} \sum_{setU} \prod_{i=1}^{n} P(X_i | parinti(X_i))$$

Calculam $P(h|m, \neg p)$, unde $Q = H$, $setE = \{m, \neg p\}$ și $setU = \{C, A\}$



$$P(h|m, \neg p) = \frac{P(h, m, \neg p)}{P(m, \neg p)}$$

$$= \frac{\sum_{A,C} P(h, m, \neg p, A, C)}{\sum_{A,C,H} P(m, \neg p, H, A, C)}$$

$$= \frac{\sum_{A,C} P(h) \cdot P(C) \cdot P(a|h, C) \cdot P(m|A) \cdot P(\neg p|A)}{\sum_{A,C,H} P(H) \cdot P(C) \cdot P(a|H, C) \cdot P(m|A) \cdot P(\neg p|A)}$$

Independență Condițională

Pe caz general: ce **relații de independență condițională** devin adevărate atunci când un subset din nodurile unei RB sunt cunoscute (observate)?

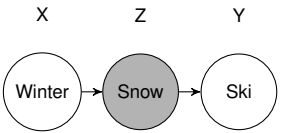
D-separarea: concept ce denotă procedura de observare a unui set de noduri Z dintr-o RB, ce face ca alte mulțimi (X și Y) să fie **independente condițional** una de alta, cunoscute fiind valorile nodurilor din Z

- $\mathbf{X} \perp \mathbf{Y} | \mathbf{Z}$
- O relație de independență condițională într-o RB se poate verifica **folosind structura grafului aciclic orientat** al rețelei

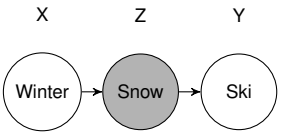
O relație de tipul $\mathbf{X} \perp \mathbf{Y} | \mathbf{Z}$ **nu** ține atunci când:

- Există o conexiune directă între *un nod* din **X** și un nod din **Y**
- Există **un lanț** / **o cale** între *un nod* din **X** și un nod din **Y**, care nu este **"blocată"** de noduri din **Z**

Analiză a conectivității a 3 noduri în graful unei RB



Analiză a conectivității a 3 noduri în graful unei RB



Lanț cauzal

X $\rightarrow$ **Z** $\rightarrow$ **Y**

X **nu influențează** *Y* dacă *Z* **observat**

Lanț de probe

X $\leftarrow$ **Z** $\leftarrow$ **Y**

Y **nu influențează** *X* dacă *Z* **observat**

Analiză a conectivității a 3 noduri în graful unei RB

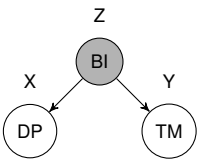


Analiză a conectivității a 3 noduri în graful unei RB

Cauză comună

X $\leftarrow$ **Z** $\rightarrow$ **Y**

X **nu influențează** *Y* dacă *Z* **observat**

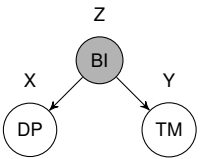


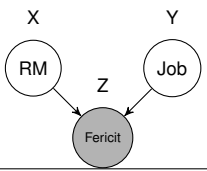
Analiză a conectivității a 3 noduri în graful unei RB

Cauză comună

X $\leftarrow$ **Z** $\rightarrow$ **Y**

X **nu influențează** *Y* dacă *Z* **observat**



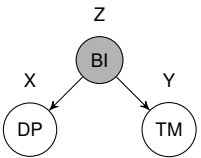


Analiză a conectivității a 3 noduri în graful unei RB

Cauză comună

X $\leftarrow$ **Z** $\rightarrow$ **Y**

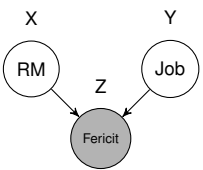
X **nu influențează** *Y* dacă *Z* **observat**



Efect comun

X $\rightarrow$ **Z** $\leftarrow$ **Y**

Y influențează *X* dacă *Z* **observat**



D-separare: analiza **căilor** care "**permit influență probabilistică**" între noduri din **X** și noduri din **Y**

O cale între un nod din X și un nod din Y se numește **blocată** / **inactivă** dacă:

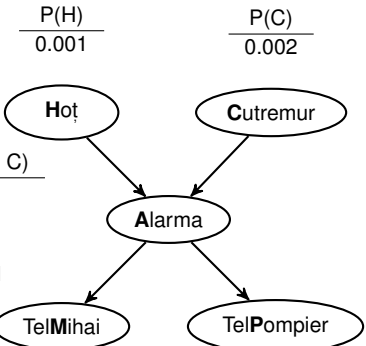
- Conține o subcale $A \rightarrow B \rightarrow C$ - **lanț cauzal** - unde B **este** observat ($B \in Z$)
- Conține o subcale $A \leftarrow B \leftarrow C$ - **lanț de probe** - unde B **este** observat ($B \in Z$)
- Conține o subcale $A \leftarrow B \rightarrow C$ - **cauză comună** - unde B **este** observat ($B \in Z$)
- Conține o subcale $A \rightarrow B \leftarrow C$ - **efect comun** - unde B *și nici unul dintre descendenții săi* **nu este** observat ($B \notin Z$ și $N \notin Z, \forall N \in desc(B)$)

- Dacă **toate căile** între noduri din X și noduri din Y sunt **inactive** $\Rightarrow$ $\mathbf{X} \perp \mathbf{Y} | \mathbf{Z}$
- Dacă **cel puțin o cale** între un nod din X și un nod din Y **este activă** $\Rightarrow$ $\mathbf{X} \not\perp \mathbf{Y} | \mathbf{Z}$

- Folosind rețele bayesiene, putem face inferențe:
  - Inferențe exacte
  - Inferențe aproximative (prin eșantionare – sampling)

Inferențe Exacte – Metoda Enumerării

Exemplul declașării alarmei:



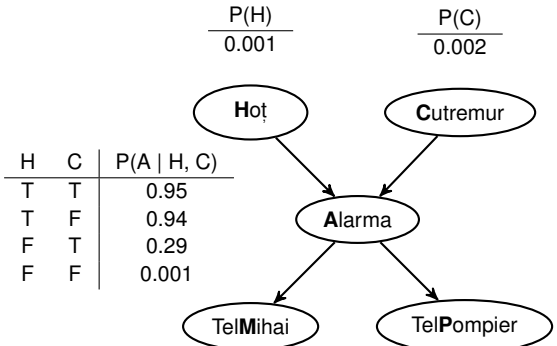
H	C	P(A | H, C)
T	T	0.95
T	F	0.94
F	T	0.29
F	F	0.001

A	P(M | A)
T	0.9
F	0.05

A	P(P | A)
T	0.7
F	0.01

$P(a|h) = ?$

Exemplul declașării alarmei:



H	C	P(A | H, C)
T	T	0.95
T	F	0.94
F	T	0.29
F	F	0.001

A	P(M | A)
T	0.9
F	0.05

A	P(P | A)
T	0.7
F	0.01

$$P(a|h) = P(a|h,c) \cdot P(c|h) + P(a|h,\neg c) \cdot P(\neg c|h)$$
$$= P(a|h,c) \cdot P(c) + P(a|h,\neg c) \cdot P(\neg c)$$

unde am utilizat faptul că $H \perp C \mid \emptyset$

Procedura de **inferență prin enumerare**:

$$P(Q|E_1, E_2, \ldots) = \frac{1}{Z} P(Q \wedge E_1 \wedge E_2, \ldots) = \frac{1}{Z} \sum_{U_1, U_2, \ldots} P(Q \wedge E_1 \wedge E_2 \wedge \ldots \wedge U_1 \wedge U_2 \wedge \ldots)$$

unde:

- Q – **variabila** aleatoare interogată
- E – **mulțimea de probe** (variabile aleatoare a căror valoare se cunoaște cu certitudine)
- U – **mulțimea de variabile aleatoare neobservate** (care împreună cu Q și E constituie evenimente mutual exclusive și exhaustive)
- $1/Z$ – **factor de normalizare** al distribuției

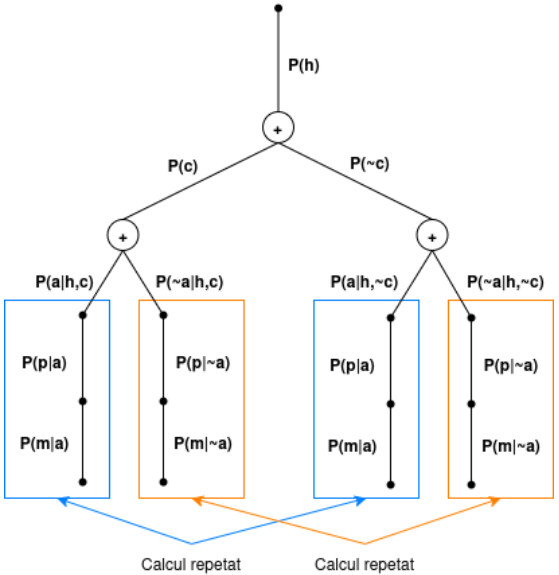
Exemplu:

$$\begin{aligned} P(h|m,p) &= \frac{1}{Z} P(h,m,p) \\ &= \frac{1}{Z} \sum_{C \in \{c, \neg c\}} \sum_{A \in \{a, \neg a\}} P(h) \cdot P(C) \cdot P(A|h,C) \cdot P(m|A) \cdot P(p|A) \end{aligned}$$

Analizând exemplul anterior, grupând și reordonând operațiile, observăm:

$$
\begin{aligned}
P(h|m,p) &= \frac{1}{Z}\sum_{C}\sum_{A} P(h)\cdot P(C)\cdot P(A|h,C)\cdot P(m|A)\cdot P(p|A) \\
&= \frac{1}{Z}\cdot P(h)\sum_{A} P(m|A)\cdot P(p|A)\sum_{C} P(C)\cdot P(A|h,C) \\
&= \frac{1}{Z}\cdot P(h)\sum_{C} P(C)\sum_{A} P(A|C,h)\cdot P(m|A)\cdot P(p|A)
\end{aligned}
$$

În procedura de inferență prin enumerare unele calcule sunt redundante. Exemplu pentru $P(h|m,p)$



Procedura de **inferență prin enumerare**:

- Pentru **n** variabile aleatoare boolene, complexitatea spațială este $O(n)$, iar cea de timp $O(2^n)$
- Putem îmbunătăți situația dacă eliminăm calcule redundante reținând rezultatele intermediare pe parcurs (ca factori în calcul)

Inferențe Exacte – Eliminarea Variabilelor

Reluând exemplul pentru $P(h|m,p)$ avem:

$$\frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

unde f_H, f_C, f_A, f_M, f_P sunt factori.

- Idee: executăm calculele de la **dreapta la stânga** (sau de jos în sus în termenii arborelui de calcul) și **memorăm** rezultatele parțiale pe parcurs, **reutilizându-le** la nevoie.

- Factorii sunt inițial asociați câte unul fiecărei variabile aleatoare (fiecărui nod) din RB.
- Un factor se reprezintă ca o tabelă indexată după toate combinațiile posibile de valori ale variabilelor incluse în factor (inițial cele din probabilitatea condiționată $P(X|parinti(X))$)

Exemplu $\mathbf{f_A}[\mathbf{A}, \mathbf{H}, \mathbf{C}]$, $\mathbf{f_P}[\mathbf{P}, \mathbf{A}]$:

A	H	C	$f_A[A, H, C]$
T	T	T	$P(a\|h, c) = 0.95$
T	T	F	$P(a\|h, \neg c) = 0.94$
T	F	T	$P(a\|\neg h, c) = 0.29$
T	F	F	$P(a\|\neg h, \neg c) = 0.001$
F	T	T	$P(\neg a\|h, c) = 0.05$
F	T	F	$P(\neg a\|h, \neg c) = 0.06$
F	F	T	$P(\neg a\|\neg h, c) = 0.71$
F	F	F	$P(\neg a\|\neg h, \neg c) = 0.999$

P	A	$f_P[P, A]$
T	T	$P(p\|a) = 0.7$
T	F	$P(p\|\neg a) = 0.01$
F	T	$P(\neg p\|a) = 0.3$
F	F	$P(\neg p\|\neg a) = 0.99$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

- Avem o RB cu 5 variabile H, C, A, M, P.
- Interogarea $P(h|m,p)$ (în care M și P sunt variabile probă / observate) necesită *"eliminarea"* variabilelor A și C

1. Reducem factorii $f_M[M,A]$ și $f_P[P,A]$ doar la liniile unde $M = T$ și $P = T$, conform observațiilor

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

- Avem o RB cu 5 variabile H, C, A, M, P.
- Interogarea $P(h|m,p)$ (în care M și P sunt variabile probă / observate) necesită *"eliminarea"* variabilelor A și C

1. Reducem factorii $f_M[M,A]$ și $f_P[P,A]$ doar la liniile unde $M = T$ și $P = T$, conform observațiilor
2. Înmulțim toți factorii care conțin pe A – $f_A[A,H,C]$, $f_M[M,A]$, $f_P[P,A]$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

- Avem o RB cu 5 variabile H, C, A, M, P.
- Interogarea $P(h|m,p)$ (în care M și P sunt variabile probă / observate) necesită *"eliminarea"* variabilelor A și C

1. Reducem factorii $f_M[M,A]$ și $f_P[P,A]$ doar la liniile unde $M = T$ și $P = T$, conform observațiilor
2. Înmulțim toți factorii care conțin pe A – $f_A[A,H,C]$, $f_M[M,A]$, $f_P[P,A]$
3. Eliminăm prin însumare variabila A (notăm cu $\overline{A}$ faptul că factorul este însumat peste A)

$$f_{\overline{A}HC}[M,P,H,C] = \sum_A f_A[A,H,C] \cdot f_M[M,A] \cdot f_P[P,A]$$

Până în acest moment interogarea se poate rescrie:

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} f_{\overline{A}HC}[M,P,H,C]$$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

Până în acest moment interogarea este reprezentată ca:

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} f_{\bar{A}HC}[M,P,H,C]$$

4. Eliminăm C folosind $f_C[C]$ și $f_{\bar{A}HC}[M,P,H,C]$ $\Rightarrow$
$f_{\bar{A}H\bar{C}}[H,M,P] = \sum_C f_C[C] \cdot f_{\bar{A}HC}[M,P,H,C]$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

Până în acest moment interogarea este reprezentată ca:

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} f_{\bar{A}HC}[M,P,H,C]$$

4. Eliminăm C folosind $f_C[C]$ și $f_{\bar{A}HC}[M,P,H,C]$ $\Rightarrow$
   $f_{\bar{A}H\bar{C}}[H,M,P] = \sum_C f_C[C] \cdot f_{\bar{A}HC}[M,P,H,C]$
5. Obținem factorul final peste H, M, P și normalizăm: $P(h|m,p) = \frac{1}{Z} f_H[H] \cdot f_{\bar{A}H\bar{C}}[M,P,H]$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

Până în acest moment interogarea este reprezentată ca:

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} f_{\bar{A}HC}[M,P,H,C]$$

4. Eliminăm C folosind $f_C[C]$ și $f_{\bar{A}HC}[M,P,H,C]$ $\Rightarrow$
   $f_{\bar{A}H\bar{C}}[H,M,P] = \sum_C f_C[C] \cdot f_{\bar{A}HC}[M,P,H,C]$
5. Obținem factorul final peste H, M, P și normalizăm: $P(h|m,p) = \frac{1}{Z} f_H[H] \cdot f_{\bar{A}H\bar{C}}[M,P,H]$
6. Citim rezultatul $P(h|m,p)$ pe linia $H = T$, $M = T$, $P = T$

Eliminarea variabilelor

$$P(h|m,p) = \frac{1}{Z} \cdot \underbrace{P(h)}_{f_H[h]} \sum_C \underbrace{P(C)}_{f_C[C]} \sum_A \underbrace{P(A|C,h)}_{f_A[A,h,C]} \cdot \underbrace{P(m|A)}_{f_M[M,A]} \cdot \underbrace{P(p|A)}_{f_P[P,A]}$$

Factorul final $\frac{1}{Z} f_H[H] \cdot f_{\bar{A}H\bar{C}}[M,P,H]$ este proporțional cu **probabilitatea comună** a variabilei de interogare (query) și a variabilelor observate.

H	M	P	$f_{\text{final}}(h,m,p)$
1	1	1	$\propto p(h,m,p) = f^1_{final}$
0	1	1	$\propto p(\neg h,m,p) = f^2_{final}$

Pentru a calcula probabilitatea cerută $p(h|m,p)$ normalizăm tabela factorului f_{final} și preluăm rezultatul de la linia h,m,p.
Factorul final normalizat

H	M	P	$p(H|m,p)$
1	1	1	$f^1_{final}/(f^1_{final} + f^2_{final})$
0	1	1	$f^2_{final}/(f^1_{final} + f^2_{final})$

Procedura eliminării variabilelor necesită existența a două operații pe factori

- **Înmulțirea** a doi factori
- **Eliminarea prin însumare** (eng. **sum out**) a unei variabile

Exemplu înmulțire: $f_M[M, A] \cdot f_P[P, A]$

M	A	$f_M[M, A]$
T	T	0.9
T	F	0.05
F	T	0.1
F	F	0.95

P	A	$f_P[P, A]$
T	T	0.7
T	F	0.01
F	T	0.3
F	F	0.99

M	A	P	$f_{MAP}[M, A, P]$
T	T	T	$0.9 \cdot 0.7 = 0.63$
T	T	F	$0.9 \cdot 0.3 = 0.27$
T	F	T	$0.05 \cdot 0.01 = 0.0005$
T	F	F	$0.05 \cdot 0.99 = 0.0495$
F	T	T	$0.1 \cdot 0.7 = 0.07$
F	T	F	$0.1 \cdot 0.3 = 0.03$
F	F	T	$0.95 \cdot 0.01 = 0.0095$
F	F	F	$0.95 \cdot 0.99 = 0.9405$

Exemplu: **însumarea** peste **A** în $f_{MAP}[M, A, P]$

$$f_{M\bar{A}P}[M, P] = \sum_{A} f_{MAP}[M, A, P] = f_{MAP}(M, a, P) + f_{MAP}(M, \neg a, P)$$

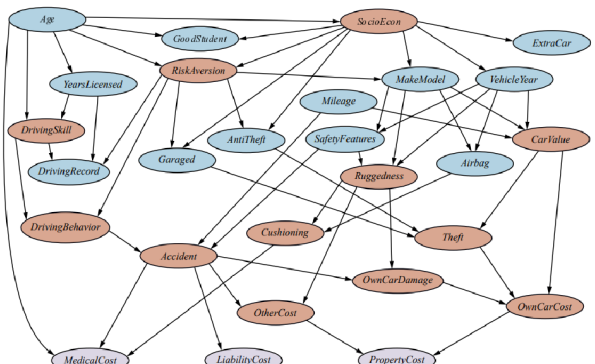
M	A	P	$f_{MAP}[M, A, P]$
T	T	T	0.63
T	T	F	0.27
T	F	T	0.0005
T	F	F	0.0495
F	T	T	0.07
F	T	F	0.03
F	F	T	0.0095
F	F	F	0.9405

M	P	$f_{MP}[M, P]$
T	T	$0.63 + 0.0005 = 0.6305$
T	F	$0.27 + 0.0495 = 0.3195$
F	T	$0.07 + 0.0095 = 0.0795$
F	F	$0.03 + 0.9405 = 0.9705$

Inferențe de Aproximare

- Motivație: Inferențele exacte în RB pot fi foarte costisitoare - în cazul cel mai rău complexitatea este exponențială în numărul de noduri (chiar și cu eficientizarea dată de Eliminarea Variabilelor)

RB pentru asigurare auto:



[AIMA, Russel & Norvig]

Inferență de aproximare - Eșantionare (Sampling)

- De ce să eșantionăm?
  - **Învățare**: obținerea de eșantioane dintr-o distribuție **necunoscută**
  - **Inferență**: obținerea de eșantioane este mai rapidă decât calculul exact

Inferență de aproximare - Eșantionare (Sampling)

- De ce să eșantionăm?
  - **Învățare**: obținerea de eșantioane dintr-o distribuție **necunoscută**
  - **Inferență**: obținerea de eșantioane este mai rapidă decât calculul exact
- Ideea de bază: eșantionarea este ca *simularea repetată*

Inferență de aproximare - Eșantionare (Sampling)

- De ce să eșantionăm?
  - **Învățare**: obținerea de eșantioane dintr-o distribuție **necunoscută**
  - **Inferență**: obținerea de eșantioane este mai rapidă decât calculul exact
- Ideea de bază: eșantionarea este ca *simularea repetată*
  - Extragem *N* eșantioane dintr-o distribuție *S*

Inferență de aproximare - Eșantionare (Sampling)

- De ce să eșantionăm?
  - **Învățare**: obținerea de eșantioane dintr-o distribuție **necunoscută**
  - **Inferență**: obținerea de eșantioane este mai rapidă decât calculul exact
- Ideea de bază: eșantionarea este ca *simularea repetată*
  - Extragem N eșantioane dintr-o distribuție S
  - Calculăm pe seama lor o **probabilitate aposteriori aproximativă** ($P(Q|e)$)

Inferență de aproximare - Eșantionare (Sampling)

- De ce să eșantionăm?
  - **Învățare**: obținerea de eșantioane dintr-o distribuție **necunoscută**
  - **Inferență**: obținerea de eșantioane este mai rapidă decât calculul exact
- Ideea de bază: eșantionarea este ca *simularea repetată*
  - Extragem N eșantioane dintr-o distribuție S
  - Calculăm pe seama lor o **probabilitate aposteriori aproximativă** ($P(Q|e)$)
  - Arătăm că probabilitatea aproximată converge (sub limită de eșantionare infinită) către probabilitatea corectă

Eșantionarea după o distribuție dată

1. Extragem un număr u dintr-o distribuție uniformă peste $[0, 1)$
2. Convertim u la un rezultat din distribuția țintă, făcând o asociere între fiecare rezultat posibil și un sub-interval din $[0, 1)$ (fiecare sub-interval fiind proporțional cu probabilitatea de alegere a acelui rezultat)

C	P(C)	
roșu	0.6	$0 \leq u < 0.6 \rightarrow C$ = roșu
verde	0.1	$0.6 \leq u < 0.7 \rightarrow C$ = verde
albastru	0.3	$0.7 \leq u < 1 \rightarrow C$ = albastru

Exemplu: pentru $u = 0.81$ culoarea extrasă: ?

Eșantionarea după o distribuție dată

1. Extragem un număr u dintr-o distribuție uniformă peste $[0, 1)$
2. Convertim u la un rezultat din distribuția țintă, făcând o asociere între fiecare rezultat posibil și un sub-interval din $[0, 1)$ (fiecare sub-interval fiind proporțional cu probabilitatea de alegere a acelui rezultat)

C	P(C)	
roșu	0.6	$0 \leq u < 0.6 \rightarrow C$ = roșu
verde	0.1	$0.6 \leq u < 0.7 \rightarrow C$ = verde
albastru	0.3	$0.7 \leq u < 1 \rightarrow C$ = albastru

Exemplu: pentru $u = 0.81$ culoarea extrasă: albastru

- Eșantionare directă (prior sampling)
- Eșantionare prin eliminarea eșantioanelor nedorite (rejection sampling)
- Eșantionare ponderată (likelihood sampling)
- Eșantionare Gibbs (Gibbs sampling)

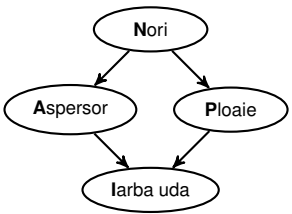
Eșantionare directă

- Se generează eșantioane dintr-o distribuție de probabilitate cunoscuta
- Cel mai simplu proces de eșantionare într-o RB: utilizat pentru a genera eșantioane/evenimente din rețea atunci când nu avem **nicio probă**
- Idee principală: eșantionăm fiecare variabilă aleatoare pe rând, **în ordine topologică**
- Distribuția de probabilitate din care se obțin valorile unei variabile din eșantion este condiționată de valorile care au fost deja atribuite părinților

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.1

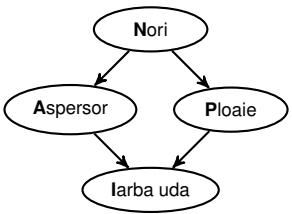
Eșantioane:

- n,
-

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.5

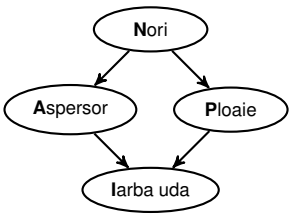
Eșantioane:

- $n, \neg a,$
-

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.2

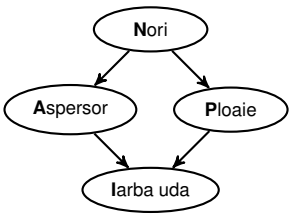
Eșantioane:

- $n, \neg a, p,$
-

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.8

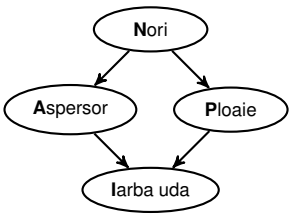
Eșantioane:

- $n, \neg a, p, i$
-

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.7

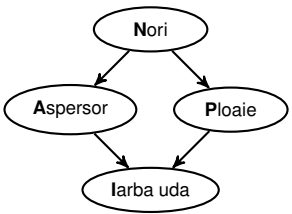
Eșantioane:

- $n, \neg a, p, i$
- $\neg n,$

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.3

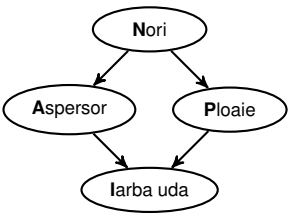
Eșantioane:

- $n, \neg a, p, i$
- $\neg n, a,$

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.9

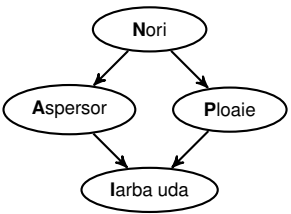
Eșantioane:

- $n, \neg a, p, i$
- $\neg n, a, \neg p,$

Eșantionare directă

N	P(N)
T	0.5
F	0.5

N	A	$P(A\|N)$
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	$P(P\|N)$
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	$P(I\|A,P)$
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Număr aleator: 0.4

Eșantioane:

- $n, \neg a, p, i$
- $\neg n, a, \neg p, i$

Aproximare : Eșantionare directă

Procedură de eșantionare directă:

Intrări: RB cu n noduri

Ieșire: un eșantion din RB

1. $x_S \leftarrow$ vector gol de lungime n
2. **pentru fiecare** variabilă X_i din $\{X_1, X_2 \ldots, X_n\}$, ordonate topologic
3. $\quad x_S[i] \leftarrow$ un eșantion aleator luat din distribuția $P(X_i|parinti(X_i))$
4. **întoarce** x_S

- Procedura generează eșantioane cu probabilitatea $S_{PS} = \prod_{i=1,n} P(X_i|parinti(X_i)) = P(X_1, X_2, \ldots, X_n)$
- Dacă notăm prin $N_{PS}(x_1, x_2, \ldots, x_n)$ numărul de ori în care a fost eșantionat evenimentul $(x_1, x_2, \ldots, x_n)$, atunci este adevărat că:

$$\lim_{n\to\infty} \hat{P}(x_1, x_2, \ldots, x_n) = \lim_{n\to\infty} \frac{N_{PS}(x_1, x_2, \ldots, x_n)}{n}$$
$$= S_{PS}(x_1, x_2, \ldots, x_n) = P(x_1, x_2, \ldots, x_n)$$

Aproximare : Eșantionare directă

De exemplu, dacă obținem eșantioanele:

- $n, \neg a, p, i$
- n, a, p, i
- $\neg n, a, p, \neg i$
- $n, \neg a, p, i$
- $\neg n, \neg a, \neg p, i$

Dacă vrem să aflăm $p(i)$ – abordare **frecventistă**:

- Numărăm $i : 4$, $\neg i : 1$
- Normalizăm și obținem $P(i) = 0.8$, $P(\neg i) = 0.2$

- Cu cât avem mai multe eșantioane, cu atât mai apropiată va fi estimarea
- Putem estima orice interogare probabilistică: e.g. $P(n|i)$, $P(n|\neg a, i)$ ...
- ... dar, pentru probabilități condiționate (e.g. $P(n|i)$) generăm și multe eșantioane care nu corespund probelor observate

Aproximare : Rejection Sampling

Motivație:

- Dacă se dorește estimarea probabilității $P(n)$, nu are sens să păstrăm și eșantioane care ar conține $\neg n$. Ajunge să **contorizăm** apariții ale lui $N = adev$ în eșantioane
- Similar și pentru o probabilitate condiționată (e.g. $P(n|a)$), putem *rejecta* eșantioane care nu au $A = adev$
  - Contorizăm apariții de $N = adev$, dar rejectăm eșantioanele în care $A = fals$

Aproximare : Rejection Sampling

Generare eșantion prin eliminarea eșantioanelor nedorite

Intrări: RB cu n noduri, set variabile probă e

Ieșire: un eșantion din RB

1. $x_S \leftarrow$ vector gol de lungime n
2. **pentru fiecare** variabilă X_i din $\{X_1, X_2 \ldots, X_n\}$, ordonate topologic
3. $\quad x_S[i] \leftarrow$ un eșantion aleator luat din distribuția $P(X_i | parinti(X_i))$
4. $\quad$ **dacă** $x_S[i]$ nu e consistentă cu probele e
5. $\quad\quad$ **atunci întoarce** $\perp$ (i.e. **nu** se generează un eșantion)
6. **întoarce** x_S

Aproximare : Eșantionare ponderată

Motivație:

- Problemă în procedura de eliminare a eșantioanelor nedorite: dacă **probele** sunt **puțin probabile** rejectăm multe eșantioane
- Nu ne folosim suficient de valorile variabilelor probă

Exemplu: dacă ne-ar interesa să calculăm $P(Forma|albastru)$ din următoarea rețea:





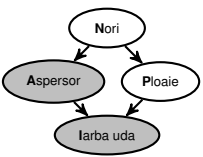
Idee: fixăm probele și eșantionăm doar restul

- Problemă: distribuția eșantioanelor nu mai e consecventă
- Soluție: **ponderăm** eșantionul după probabilitatea condiționată a variabilelor probă, dați fiind părinții

Exemplu "de mână" în problema Ierbii ude

N	P(N)
N	0.5
¬*N*	0.5

N	A	P(A | N)
T	T	0.1
T	F	0.9
F	T	0.9
F	F	0.1



N	P	P(P | N)
T	T	0.8
T	F	0.2
F	T	0.2
F	F	0.8

A	P	I	P(I | A, P)
T	T	T	0.99
T	T	F	0.01
T	F	T	0.90
T	F	F	0.10
F	T	T	0.90
F	T	F	0.10
F	F	T	0.01
F	F	F	0.99

Presupunem $A = adev$ și $I = adev$ observate

- Eșantionul n, a, p, i are pondere $w = 1 \cdot P(a|n) \cdot P(i|a, p) = 1 \cdot 0.1 \cdot 0.99$
- Eșantionul $\neg n$, a, $\neg p$, i are pondere $w = 1 \cdot P(a|\neg n) \cdot P(i|a, \neg p) = 1 \cdot 0.9 \cdot 0.99$

Eșantionare ponderată

Intrări: *RB* – Rețeaua Bayesiană;
probe – mulțimea de variabile probă cunoscute;
n – numărul de noduri din RB

Ieșire: Tuplu: Un eșantion din RB, pondere *w*

1. $w \leftarrow 1.0$
2. $x_S \leftarrow$ vector gol de lungime n
3. **pentru fiecare** variabilă X_i din $\{X_1, X_2 \ldots, X_n\}$, ordonate topologic
4. **dacă** X_i este variabilă cu valoare în *probe*
5. $x_S[i] \leftarrow x_i$, valoarea observată pentru X_i
6. $w \leftarrow w \cdot P(x_i | parinti(X_i))$
7. **altfel**
8. Eșantionează x_i din $P(X_i | parinti(X_i))$
9. $x_S[i] \leftarrow x_i$
10. **întoarce** x_S, w

Aproximare : Eșantionare ponderată

- Eșantionarea ponderată ajută să **ținem cont de probe** atunci când generăm eșantioane $\Rightarrow$ eficientizarea eșantionării
- **Problemă**: Probele influențează (restricționează) îndeosebi variabilele lor *descendente*. Cele părinte nu se selectează conform cu probabilitatea de a genera probele
- Cerință: a ține cont de variabilele probă când eșantionăm **oricare** altă variabilă

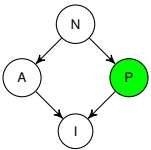
Aproximare : Eșantionare Gibbs

Eșantionare Gibbs – parte din familia procedurilor Markov Chain Monte Carlo (de fapt, o particularizare a procedurii Metropolis-Hastings)

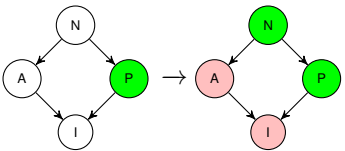
Idee:

- Eșantionăm câte o variabilă pe rând, **condiționând în raport cu toate celelalte**, iar variabilele probă rămân fixate
- Eșantioanele nou generate **nu mai sunt independente** (vor fi aproape identice), dar **media** eșantioanelor reprezintă o estimare consecventă

Aproximare : Eșantionare Gibbs

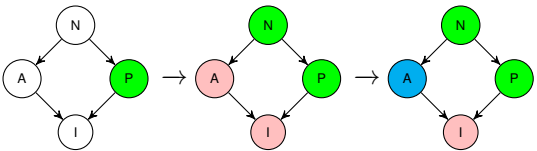


1. Fixare probă: $P = adev$



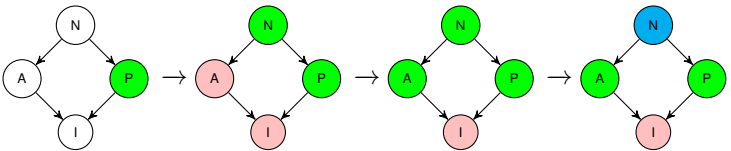
1. Fixare probă: $P = adev$
2. Eșantion inițial aleator $\rightarrow \{\neg a, n, \neg i\}$
3. stabilește secvență variabile non-probă $\{A, N, I\}$

Aproximare : Eșantionare Gibbs



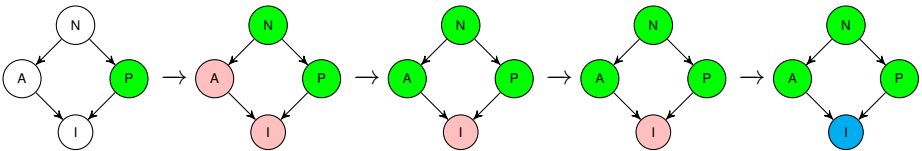
1. Fixare probă: $P = adev$
2. Eșantion inițial aleator $\rightarrow \{\neg a, n, \neg i\}$
3. stabilește secvență variabile non-probă $\{A, N, I\}$
4. repetă:
5. alege variabilă X din secvență — alege A
6. Eșantionează X din $P(X|restul)$ — eșantion a după $n, p, \neg i \Rightarrow$ este adevărat

Aproximare : Eșantionare Gibbs



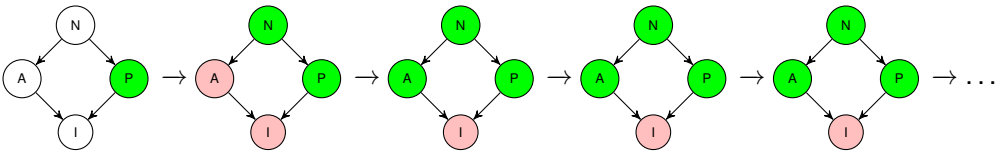
1. Fixare probă: $P = adev$
2. Eșantion inițial aleator $\rightarrow \{\neg a, n, \neg i\}$
3. stabilește secvență variabile non-probă $\{A, N, I\}$
4. repetă:
5. alege variabilă X din secvență — alege N
6. Eșantionează X din $P(X|restul)$ — eșantion n după $a, p, \neg i \Rightarrow$ este adevărat

Aproximare : Eșantionare Gibbs



1. Fixare probă: $P = adev$
2. Eșantion inițial aleator $\rightarrow \{\neg a, n, \neg i\}$
3. stabilește secvență variabile non-probă $\{A, N, I\}$
4. repetă:
5. alege variabilă X din secvență — alege I
6. Eșantionează X din $P(X|restul)$ — eșantion i după $n, a, p \Rightarrow$ este fals

Aproximare : Eșantionare Gibbs



1. Fixare probă: $P = adev$
2. Eșantion inițial aleator $\rightarrow \{\neg a, n, \neg i\}$
3. stabilește secvență variabile non-probă $\{A, N, I\}$
4. repetă:
5. alege variabilă X din secvență
6. Eșantionează X din $P(X|restul)$

Eșantionare Gibbs: eșantionarea unei variabile $P(A|N, P, \neg I)$

$$
\begin{aligned}
p(a|n, p, \neg i) &= \frac{p(a, n, p, \neg i)}{p(n, p, \neg i)} \\
&= \frac{p(a, n, p, \neg i)}{\sum_A p(A, n, p, \neg i)} \\
&= \frac{p(n) \cdot p(a|n) \cdot p(p|n) \cdot p(\neg i|a, p)}{\sum_A p(n) \cdot p(A|n) \cdot p(p|n) \cdot p(\neg i|A, p)} \\
&= \frac{p(n) \cdot p(a|n) \cdot p(p|n) \cdot p(\neg i|a, p)}{p(n) \cdot p(p|n) \cdot \sum_A p(A|n) \cdot p(\neg i|A, p)} \\
&= \frac{p(a|n) \cdot p(\neg i|a, p)}{\sum_A p(A|n) \cdot p(\neg i|A, p)}
\end{aligned}
$$

- **Observație**: doar tabelele de probabilitate condiționate ce implică A rămân
- Pe caz general, doar tabelele de probabilitate condiționate ce implică variabila re-eșantionată trebuie luate în considerare și reunite (ca factori)

Sumar tehnici de eșantionare:

- Eșantionare directă (prior sampling):
  - Utilă atunci când dorim estimarea unei probabilități necondiționate: $P(Q)$
  - simplă, dar ineficientă în caz că dorim estimarea unei probabilități condiționate (generează multe eșantioane neutilizate)
- Eșantionare cu eliminarea eșantioanelor nedorite:
  - Poate fi folosită pentru estimarea de probabilități condiționoate (unde o parte din variabile sunt *probe* – $P(Q|e)$)
  - Mai eficientă decât eșantionarea directă
- Eșantionare ponderată:
  - Poate fi folosită pentru estimarea de probabilități condiționoate (unde o parte din variabile sunt *probe* – $P(Q|e)$)
  - Mai eficientă decât procedurile anterioare, dar probele condiționează doar generarea *descendenților*
- Eșantionare Gibbs:
  - Poate fi folosită pentru estimarea de probabilități condiționoate (unde o parte din variabile sunt *probe* – $P(Q|e)$)
  - Mai eficientă decât procedurile anterioare: probele afectează eșantionarea atât a variabilelor descendente, cât și părinte

Mulțumesc!



https://forms.gle/DJUdkejstkvyNRF5A

Feedbackul este binevenit!