Inteligență Artificială

Introducere în învățarea automată

Slides: Mihai Trăscău, Alexandru Sorici, Andrei Olaru

- Definiție
- Caracteristici
- Tipuri de predicție în practică

Despre un program de calculator se poate spune că învață din experiența E referitoare la o clasă de sarcini de rezolvat T și o măsură de performanță P, dacă performanța P pentru sarcina T *crește*, odată asimilată experiența E.

Tom Mitchell

Învățarea automată este un proces prin care se iau decizii sau se fac predicții bazat pe date.

Nu este singurul domeniu (disciplină) care lucrează cu date:

- Statistică – Ce model statistic explică cel mai bine datele?

Nu este singurul domeniu (disciplină) care lucrează cu date:

- Statistică – Ce model statistic explică cel mai bine datele?
- Economie, Econometrie, ... – Care sunt indicatorii care prezic cel mai bine fenomenele economice (e.g. crize financiare)?

Nu este singurul domeniu (disciplină) care lucrează cu date:

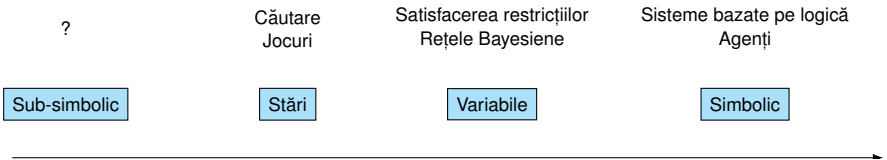
- Statistică – Ce model statistic explică cel mai bine datele?
- Economie, Econometrie, ... – Care sunt indicatorii care prezic cel mai bine fenomenele economice (e.g. crize financiare)?
- Psihologie, Sociologie, ... – Care sunt șabloanele comportamentale care emerg când analizăm date despre, de exemplu, comportamentul consumatorilor?

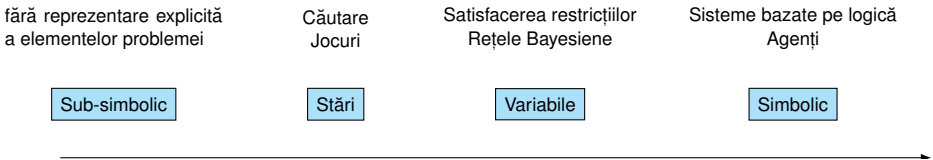
Nu este singurul domeniu (disciplină) care lucrează cu date:

- Statistică – Ce model statistic explică cel mai bine datele?
- Economie, Econometrie, ... – Care sunt indicatorii care prezic cel mai bine fenomenele economice (e.g. crize financiare)?
- Psihologie, Sociologie, ... – Care sunt șabloanele comportamentale care emerg când analizăm date despre, de exemplu, comportamentul consumatorilor?
- Medicină – Care este tratamentul cel mai potrivit pentru o anumită patologie?

Nu este singurul domeniu (disciplină) care lucrează cu date:

- Statistică – Ce model statistic explică cel mai bine datele?
- Economie, Econometrie, ... – Care sunt indicatorii care prezic cel mai bine fenomenele economice (e.g. crize financiare)?
- Psihologie, Sociologie, ... – Care sunt șabloanele comportamentale care emerg când analizăm date despre, de exemplu, comportamentul consumatorilor?
- Medicină – Care este tratamentul cel mai potrivit pentru o anumită patologie?
- ...


?
Căutare
Jocuri
Satisfacerea restricțiilor
Rețele Bayesiene
Sisteme bazate pe logică
Agenți
Sub-simbolic
Stări
Variabile
Simbolic


fără reprezentare explicită
a elementelor problemei
Căutare
Jocuri
Satisfacerea restricțiilor
Rețele Bayesiene
Sisteme bazate pe logică
Agenți
Sub-simbolic
Stări
Variabile
Simbolic

Modele sub-simbolice:

$x \Rightarrow \boxed{f} \Rightarrow y$

- x - intrare
- f - model de predicție
- y - ieșire

Predictorul f operează asupra datelor de intrare x și produce un răspuns la ieșire y.

Intrarea x poate fi, în general, de orice formă dorim (imagini, clipuri video, propoziții, secvențe de date, etc.) însă ieșirea y va fi restricționată în funcție de tipul de predicție pe care îl face modelul.

Predictorul f este ajustat în procesul de învățare pentru a genera (pe cât posibil) valori corecte pentru y corespunzătoare intrărilor x.

Ce probleme fundamentale încearcă modelele bazate pe învățare să rezolve?

- **Estimare**: Plecând de la date existente, colectate (de cele mai multe ori cu zgomot) pentru o problemă dată, acestea trebuie utilizate de model pentru a învăța să producă estimate sau predicții pentru date noi din problemă.

- **Generalizare**: Cum putem realiza predicții bune pe eșantioane de date pe care nu le-am mai întâlnit până acum (nu fac parte din setul de date disponibil în etapa de învățare)?

Clasificări binare

Clasificări binare

- Clasificarea email-ului
  - Intrări: text al unui mesaj + meta-date ale transmiterii email-ului
  - Ieșire: **spam** sau **non-spam**
- Detecția fraudelor în tranzacții cu cardul
  - Intrări: istoric indexat în timp al operațiilor cu cardul (e.g. nume comerciant, bun cumpărat, loc, sumă a tranzacției)
  - Ieșire: **fraudă** sau **activitate legitimă**
- Clasificarea șansei de a cumpăra un produs într-o campanie de vânzări
  - Intrări: istoric al conversației audio între un agent de vânzări și un client
  - Ieșiri: cumpără vs. nu cumpără

Clasificare multinomială (eng. multi**class** classification)

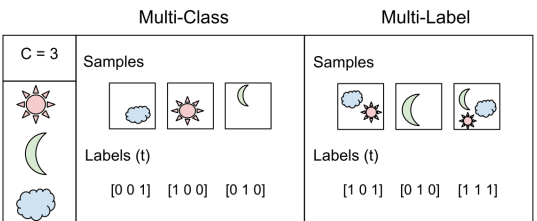
Clasificare multinomială (eng. multi**class** classification)

- Clasificarea severității unei afecțiunii de tromboembolism pulmonar
  - Intrări: investigații medicale (e.g. imagini CT, rezultate în formă tabelară a unor analize, rezultat anamneză – istoric medical)
  - Ieșire: TEP mic, TEP mediu, TEP mare
- Clasificarea semnelor de circulație în conducerea autonomă
  - Intrări: Imagine close-up al unui semn de circulație
  - Ieșire: Numele semnului de circulație conform codului rutier român
- Clasificarea activității umane
  - Intrări: secvență de valori de accelerometru pe 3 axe și unghiuri de giroscop, eșantionate la 50Hz, provenite de la un smartwatch sau smartphone
  - Ieșire: mers, alergat, urcat scări, coborât scări, staționare în picioare, staționare în șezut

Clasificare multi-etichetă (eng. multi**label** classification)

Clasificare multi-etichetă (eng. multi**label** classification)

- *Ce* semne de circulație sunt într-o imagine:
  - Intrări: poză de la nivelul unei camere de bord a mașinii
  - Ieșiri: listă de semne (din setul enumerat în codul de legislație rutieră român) existente în imagine



Clasificare mulinomială vs. multi-etichetă. Sursă imagine: Blog Raul Gomez

Regresie

Regresie

- Predicția timpului estimat de ajungere într-un loc (ETA prediction)
  - Intrări: graf al străzilor și intersecțiilor dintr-un oraș, ruta aleasă, istoric și estimare actuală a numărului de mașini pe rută la ora curentă de plecare, istoric și estimare a vitezei medii pe rută, estimare a duratei semafoarelor pe rută
  - Ieșire: durată estimată a călatoriei
- Predicție a valorii unei acțiuni la bursă
  - Intrări: istoric la nivel de oră al prețului de tranzacționare, istoric al numărului de ordine de cumpărare și vânzare, știri în media socială despre compania tranzacționată, știri în presă despre decizii politice care influențează industria în care activează compania tranzacționată
  - Ieșire: predicție a prețului acțiunii pe următoarele 8h

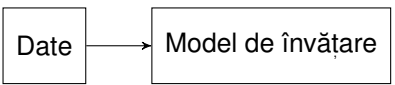
Predicții structurate

Predicții structurate

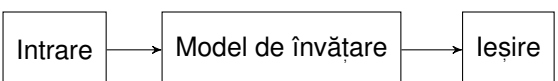
- Traducere automată
  - Intrări: propoziție în română
  - Ieșiri: propoziție în engleză
- Descrierea unei imagini
  - Intrări: imagine
  - Ieșiri: propoziție / frază descriind ce se vede în imagine
- Segmentarea semantică a unei imagini
  - Intrare: imagine
  - Ieșire: o "mască" de segmentare care regrupează pixelii care fac parte dintr-o o aceeași categorie semantică (e.g. pietoni, vehicule, drum, restul)

Notă: un proces de predicție structurată poate fi deseori descompus în procese de regresie și/sau clasificare individuale: e.g detecția obiectelor într-o imagine – proces de regresie (coordonate pixeli obiect) + clasificare (ce fel de obiect este)

Învățare nesupervizată

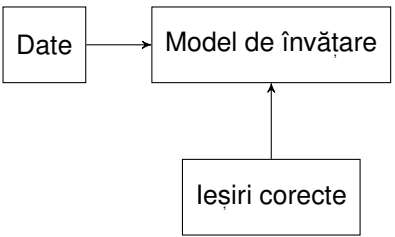


antrenare (*training*)

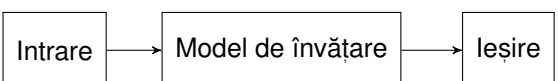


utilizare

Învățare supervizată

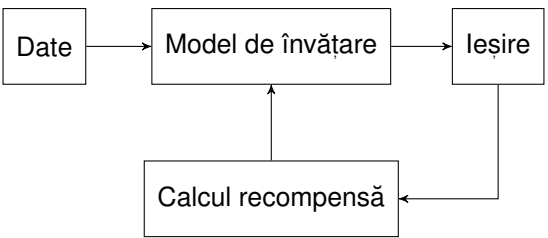


antrenare (*training*)



utilizare

Învățare prin recompensă



Exemple Metode de Învățare Supervizată:

- **Clasificare** – ieșirea modelului de învățare este o **etichetă**
  - Arbori de decizie
  - Ensemble Learning: păduri aleatoare (Random Forest), Adaptive / Gradient Boosting
  - Regresie logistică
  - Support Vector Machines (SVM)
  - Clasificare probabilistică (Naive Bayes)
  - K-Nearest Neighbours (k-NN)
  - Diferite arhitecturi de Rețele Neurale
- **Regresie:** – ieșirea modelului de învățare este o **valoare numerică** (predicția unei funcții într-un punct)
  - Regresie liniară
  - Arbori de regresie
  - Support Vector Regression (SVR)
  - K-Nearest Neighbours (k-NN pentru regresie)

Exemple Metode de Învățare Nesupervizată:

- Clustering
  - K-Means
  - Clusterizare ierarhică
- Rețele Neurale
  - Rețele Neurale cu Auto-Organizare
  - Rețele de tip Encoder-Decoder, Auto-Encoder
  - Metode de învățare prin contrastare
- Expectation Maximization (EM)
  - Învățarea parametrilor din date pentru modele grafice probabilistice (PGM): e.g. Rețele Bayesiene cu date incomplete, Modele Markov Ascunse (HMM)
  - Soft Clustering – clasele se pot suprapune
- Principal Component Analysis (PCA) – metodă folosită des pentru reducerea dimensionalității datelor

Problemele pentru care sunt aplicabile modelele cu învățare automată prezintă câteva caracteristici cheie:

- **Tipul problemei** – Ce tip de date avem la intrare și ce fel de predicții/estimări este necesar să facem?
- **Ipoteze** – Ce cunoaștem sau presupunem despre modul în care sunt generate datele? Dar despre cum trebuie să arate soluția?
- **Criterii de evaluare** – Plecând de la scopul de rezolvat în model:
  - Cum furnizăm o **funcție obiectiv** pe care să o optimizăm? Cum minimizăm un **semnal de eroare**? Cum maximizăm **un semnal de recompensă**?
  - Ce criterii definim pentru a **măsura performanța** modelului dezvoltat?

Ipoteze asupra datelor – exemple

- Date **independente și distribuite identic** (IID)
  - Exemplu: poze cu feluri de mâncare pe internet, poze cu semne de circulație de la camera de bord a unei mașini
  - **Atenție**: IID se referă la **procesul** prin care sunt obținute datele: e.g. pozarea unui semn de circulație în București este independent de pozarea în Sibiu, iar semnele sunt aceleași în toată țara
- Date **generate dintr-un proces Markov**
  - Exemplu: traducere automată sau descrierea unei imagini: **generarea** unui cuvânt nou într-o propoziție **depinde** de cuvintele generate anterior
- Date **generate adversarial**
  - Exemplu: modele de detecție de deep-fakes. Generez o față falsă, pornind de la una reală, pe care un model o distinge bine de una falsă.

Ipoteze asupra datelor – exemple

- **Zgomot** (Noise) în date
  - Zgomot pe intrări: valorile atributelor datelor sunt afectate de erori de procesare / înregistrare
  - Zgomot pe ieșiri: ieșirile sunt alterate, e.g. etichetarea exemplelor cu clasa incorectă într-un set de date

- **Observabilitate completă vs. atribute lipsă:**
  - Exemplele dintr-un dataset pot avea **valori lipsă** pentru un anumit atribut (nu tot timpul același)

Ipoteze asupra datelor – exemple

- **Bias în etichete**
  - Exemplu: Vreau să învăț să detectez fețe omenești, dar am multe exemple de fețe de la persoane caucaziene etichetate, dar mult mai puține afro-americane sau asiatice
- **Distribuție dezechilibrată a claselor**
  - Exemplu: construiesc un model pentru detecția cancerului și descopăr că setul meu de date are 99% persoane sănătoase și 1% afectați de o formă de cancer (nici măcar același cancer)

Notă: ipotezele asupra datelor influențează:

- Alegerea modelelor folosite în predicție
- Estimarea dimensiunii setului de date necesar învățării
- Necesitatea de **augmentare** a datelor (e.g. generarea artificială de exemple suplimentare, completarea datelor lipsă)

Ipoteze asupra soluției

- **Regimuri de învățare** (cum procesează modelul datele)
  - La nivel de **calup** (eng. batch)
  - La nivel **incremental** (în secvență)

- Utilizarea de **ipoteze preferate ale inducției** (inductive bias)
  - O mulțime de presupuneri (explicite sau implicite) pe care algoritmul de învățare se bazează pentru a obține un model (a generaliza) din setul de învățare

Ipoteze asupra soluției

- Utilizarea de **ipoteze preferate ale inducției**(inductive bias)
  - Spațiu de ipoteze restricționat (Restricted Bias): e.g. utilizarea de funcții liniare sau polinomiale de ordin mic
  - Ipoteză preferată (Preference Bias)
    - Occam's razor
    - Naive Bayes – toate efectele sunt independente unul de altul, dată fiind cauza
    - K-Nearest Neighbours – "ce se aseamănă, se adună"
    - Margine maximă la SVM
    - Regularizare: prefer soluții cu parametrii (ponderi) mici
    - CNN - ordonarea în spațiu a datelor are un sens
    - RNN - ordinea de apariție în secvență a datelor are un sens

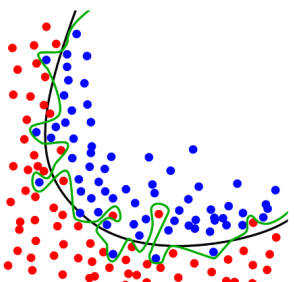
Ipoteze asupra soluției

- Principiul lamei lui Occam (lex parsimoniae) – Occam's Razor
  - Wiliam of Occam (1285 – 1347) – călugăr franciscan, filozof englez
  - prefera explicațiile simple celor complexe
  - selectează ipoteza care implica cele mai puține presupuneri, între ipoteze similare/egal probabile



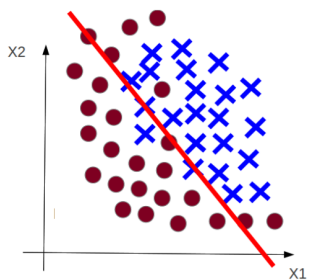
Overfitting vs. Underfitting

- **Overfitting** = modelul aplicat pe datele de învățare ajunge *să surprindă / să modeleze* zgomotul sau să detecteze șabloane (pattern-uri) de date nerelevante
- Rezultat: nu mai poate **generaliza**
- Soluție: aplicarea tehnicilor de **regularizare**



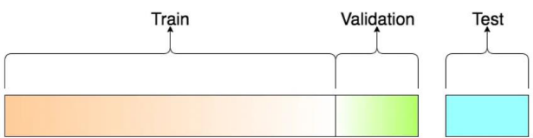
Overfitting vs. Underfitting

- **Underfitting** = modelul nu se potrivește nici datelor de învățare și nici nu poate generaliza la date noi
- Rezultat: modelul nu generalizează
- Soluție: creșterea complexității modelului



Împărțirea setului de date

- **Training set**, **Validation set**, **Test set**
  - **Setul de antrenare**: utilizat pentru antrenarea modelului
  - **Setul de validare**: validarea modelului, ajustarea hiperparametrilor (e.g. coeficient de regularizare)
  - **Setul de testare**: verificarea corectitudinii a ceea ce s-a învățat
- Împărțire tipică:
  - 80% Antrenare – 20% Test
  - 70% Antrenare – 10% Validation – 20% Test



Criterii de evaluare

- Calitatea predicțiilor unui model este adesea exprimată prin intermediul unei funcții obiectiv / **de eroare** (eng. objective function, **loss** function). Exemple:
  - Eroare pătratică: $L(y_{gt}, y_{pred}) = (y_{gt} - y_{pred})^2$
  - Eroare absolută: $L(y_{gt}, y_{pred}) = |y_{gt} - y_{pred}|$
  - Eroare cross-entropie: utilizată de regulă în clasificare, atunci când y_{gt} și y_{pred} sunt distribuții de probabilitate
  - Criteriul **plauzibilității maxime** (eng. Maximum Likelihood) – folosită des în probleme de clasificare sau predicții structurate
  - Criteriul **divergenței Kullback-Leibler**: folosit des în probleme de predicții structurate, clasificare sau învățare nesupervizată / adversarială – măsoară *similaritatea* a două distribuții de probabilitate

Criterii de evaluare

- **Performanța** la **test** (în practică) a unui model de predicție se măsoară prin **metrici de performanță**. Exemple:
  - Eroarea absolută / pătratică medie
  - **Acurateţ̦e**, **Precizie**, **Regăsire (Recall)**, **scor F1** – utilizate des în probleme de clasificare
  - **Matrice de confuzie** – utilizată des în probleme de clasificare multinomială

- Eroarea pătratică medie (*Mean Squared Error*)
  - folosită des în probleme de regresie pentru un orizont de timp mai lung de 1

$$MSE = \frac{1}{n}\sum_{i=1}^{n}\left(Y_i - \hat{Y}_i\right)^2$$

- Eroarea absolută medie (*Mean Absolute Error*)

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|Y_i - \hat{Y}_i|$$

- Matricea de confuzie

		Predicție	
	Total P + N	Pozitiv	Negativ
Real	Pozitiv	True Positive (TP)	False Negative (FN)
	Negativ	False Positive (FP)	True Negative (TN)

Vezi și wikipedia

- Matricea de confuzie
- Acuratețe (*Accuracy*)

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

		Predicție	
	Total P + N	Pozitiv	Negativ
Real	Pozitiv	True Positive (TP)	False Negative (FN)
	Negativ	False Positive (FP)	True Negative (TN)

Vezi și wikipedia

- Matricea de confuzie
- Acuratețe (*Accuracy*)

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

- Precizie (*Precision*)

$$Prec = \frac{TP}{TP + FP}$$

		Predicție	
	Total P + N	Pozitiv	Negativ
Real	Pozitiv	True Positive (TP)	False Negative (FN)
	Negativ	False Positive (FP)	True Negative (TN)

Vezi și wikipedia

- Matricea de confuzie
- Acuratețe (*Accuracy*)

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

- Precizie (*Precision*)

$$Prec = \frac{TP}{TP + FP}$$

- Regăsire (*Recall*)

$$Rec = \frac{TP}{TP + FN}$$

		Predicție	
	Total P + N	Pozitiv	Negativ
Real	Pozitiv	True Positive (TP)	False Negative (FN)
	Negativ	False Positive (FP)	True Negative (TN)

Vezi și wikipedia

- Matricea de confuzie
- Acuratețe (*Accuracy*)

$$Acc = \frac{TP + TN}{TP + TN + FP + FN}$$

- Precizie (*Precision*)

$$Prec = \frac{TP}{TP + FP}$$

- Regăsire (*Recall*)

$$Rec = \frac{TP}{TP + FN}$$

- Scor F1 (*F1-score*)

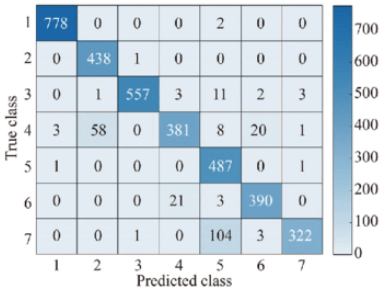
$$F1 = 2 \cdot \frac{Prec \cdot Rec}{Prec + Rec}$$

		Predicție	
	Total P + N	Pozitiv	Negativ
Real	Pozitiv	True Positive (TP)	False Negative (FN)
	Negativ	False Positive (FP)	True Negative (TN)

Vezi și wikipedia

- Matrice de confuzie – utilizată des în probleme de clasificare multinomială

vezi și wikipedia



sursa: Researchgate

Tipuri de predicție în practică

Studiu de caz: **conducere autonomă** – proiectul Nemo Drive



Problemă de regresie: Predicția unghiului de volan, dat fiind imaginea + viteza curentă



Problemă de Predicția structurată: segmentarea drumului vs. restul



Problemă de clasificare multilabel: ce entități se observă în imagine (e.g. pietoni, drum navigabil)



Problemă de predicție structurată: detecția pietonilor

Mulțumesc!



https://forms.gle/DJUdkejstkvyNRF5A

Feedbackul este binevenit!