Inteligență Artificială

Arbori de decizie

Slides: Mihai Trăscău

- Învățare inductivă
- ID3
- Păduri aleatoare

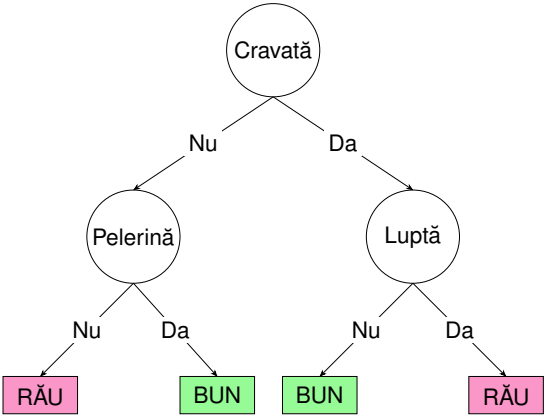
- Învățarea inductivă tratează învățarea ca pe o problemă de achiziție a cunoștințelor structurate
- Învățarea inductivă cu arbori de decizie se bazează pe generarea unor arbori care modelează cunoștințele și permit luarea de decizii
- Arborii de decizie sunt folosiți în probleme de clasificare
- Antrenarea arborilor de decizie se încadrează la învățare supervizată
- Strategia de învățare utilizează toate datele de la început (ne-incremental)
- Strategia de învățare este constructivistă, iar arborele este generat dinspre rădăcină spre frunze (*Top-Down Induction*)



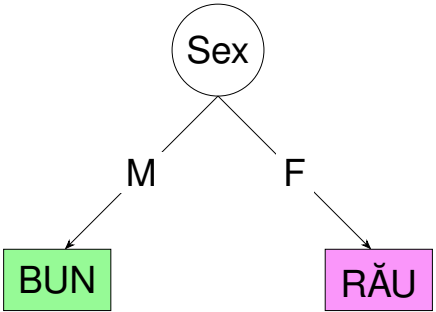
Exemplu problemă de învățare:

Care personaje DC sunt ***bune*** sau ***rele*** după felul în care se îmbracă?

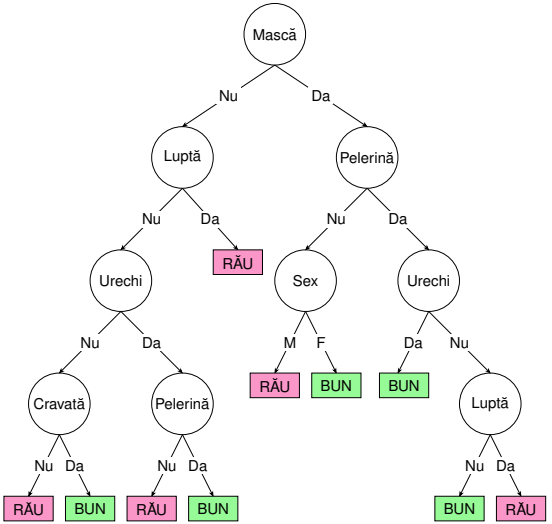
Instanțe \ Atribute	Sex	Mască	Pelerină	Cravată	Urechi	Luptă	Clasă
Set de învățare (antrenare)							
Batman	M	Da	Da	Nu	Da	Nu	BUN
Robin	M	Da	Da	Nu	Nu	Nu	BUN
Alfred	M	Nu	Nu	Da	Nu	Nu	BUN
Pinguin	M	Nu	Nu	Da	Nu	Da	RĂU
Catwoman	F	Da	Nu	Nu	Da	Nu	RĂU
Joker	M	Nu	Nu	Nu	Nu	Nu	RĂU
Set de testare							
Batgirl	F	Da	Da	Nu	Da	Nu	?
Fred	M	Da	Nu	Nu	Nu	Nu	?



Ce înseamnă un arbore bun? Clasifică corect datele?



Ce înseamnă un arbore bun? Clasfică corect datele?



Ce înseamnă un arbore bun? Clasifică corect datele?

- Clasificatoarele trebuie să fie suficient de *„expresive”* pentru a modela corect setul de învățare
- Complexitatea prea mare a clasificatoarelor pot duce la overfitting

- Algoritmul ID3 (propus de Ross Quinlan) este utilizat pentru a construi arbori de decizie bazat pe setul de date de antrenare
- Universul de obiecte U (exemple, sample-uri, etc.) este descris prin setul de atribute A
- Fiecare atribut A_i măsoară o caracteristică (mai mult sau mai puțin importantă) a unui obiect $o \in U$
- Domeniul de valori pentru atribute, $D(A_i)$, este considerat discret, simbolic
- Fiecare obiect aparține unei clase dintr-o mulțime de clase mutual exclusive C
- Plecând de la setul de învățare SI, scopul este de a obține unor reguli de clasificare prin construirea unui arbore de decizie care clasifică corect nu numai $\forall o \in SI$ dar și $\forall o \in U$

Setul de învățare:

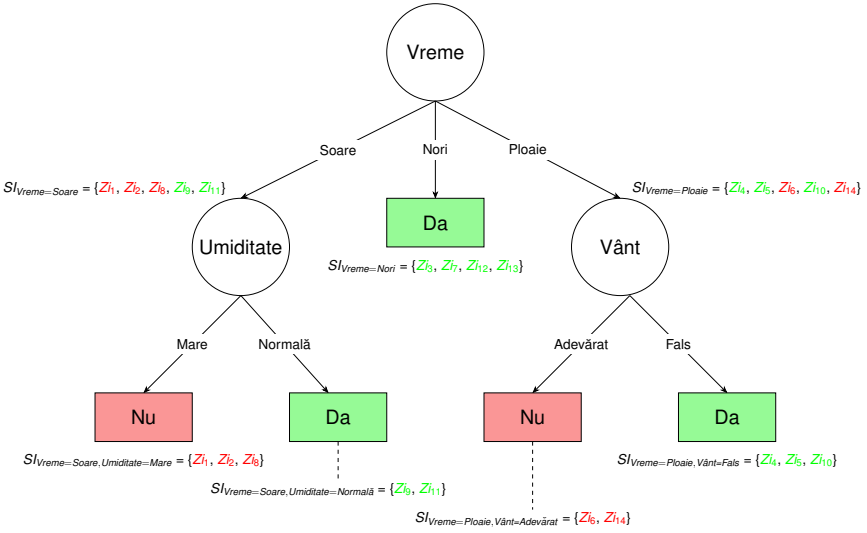
Zi	Vreme	Temperatură	Umiditate	Vânt	Clasă
1	Soare	Cald	Mare	Fals	Nu
2	Soare	Cald	Mare	Adevărat	Nu
3	Nori	Cald	Mare	Fals	Da
4	Ploaie	Plăcut	Mare	Fals	Da
5	Ploaie	Răcoare	Normal	Fals	Da
6	Ploaie	Răcoare	Normal	Adevărat	Nu
7	Nori	Răcoare	Normal	Adevărat	Da
8	Soare	Plăcut	Mare	Fals	Nu
9	Soare	Răcoare	Normal	Fals	Da
10	Ploaie	Plăcut	Normal	Fals	Da
11	Soare	Plăcut	Normal	Adevărat	Da
12	Nori	Plăcut	Mare	Adevărat	Da
13	Nori	Cald	Normal	Fals	Da
14	Ploaie	Plăcut	Mare	Adevărat	Nu

Setul de învățare:

Zi	Vreme	Temperatură	Umiditate	Vânt	Clasă
1	Soare	Cald	Mare	Fals	Nu
2	Soare	Cald	Mare	Adevărat	Nu
3	Nori	Cald	Mare	Fals	Da
4	Ploaie	Plăcut	Mare	Fals	Da
5	Ploaie	Răcoare	Normal	Fals	Da
6	Ploaie	Răcoare	Normal	Adevărat	Nu
7	Nori	Răcoare	Normal	Adevărat	Da
8	Soare	Plăcut	Mare	Fals	Nu
9	Soare	Răcoare	Normal	Fals	Da
10	Ploaie	Plăcut	Normal	Fals	Da
11	Soare	Plăcut	Normal	Adevărat	Da
12	Nori	Plăcut	Mare	Adevărat	Da
13	Nori	Cald	Normal	Fals	Da
14	Ploaie	Plăcut	Mare	Adevărat	Nu

Sunt condițiile bune pentru a juca golf?

Arbore de decizie minim:



- Plecând de la același set de învățare putem construi arbori de decizie diferiți
- Cum se poate obține cel mai mic arbore? (principiul lamei lui Occam)
- Cum selectăm atributele din fiecare nod?

Supoziții de bază pentru arborii de decizie:

- Un arbore de decizie va clasifica obiectele proporțional cu reprezentarea lor în *SI*
  - Un obiect va face parte din clasa C_k cu probabilitatea $\frac{|C_k|}{\sum_i |C_i|}$
- Când un arbore de decizie este utilizat în clasificarea obiectelor, acesta întoarce o clasă pentru obiectul dat
  - Putem privi arborii de decizie în acest proces (de inferență) ca fiind surse de mesaje (clasa fiecărui obiect) bazat pe informația extrasă din SI

- Teoria informației ne oferă un criteriu util pentru a caracteriza utilitatea unui atribut
- Aceasta se ocupă cu studiul teoretic privind reprezentarea, stocarea și comunicarea informației
- Se dă un univers de mesaje $M = \{m_1, m_2, ..., m_n\}$
- Se dă probabilitatea de apariție a unui mesaj $p(m_i)$ în contextul unei comunicări
- Definim conținutul informațional $I(M)$ al mesajelor din M:

$$I(M) = \sum_{i=1}^{n} -p(m_i) log_2(p(m_i))$$

- Adaptăm conceptul de conținut informațional pentru arbori de decizie și clasele sale C_i, calculat peste exemplele din SI

$$I(AD_{SI}) = \sum_{i=1}^{m} \left[-\frac{|C_i|}{\sum_{j=1}^{m} |C_j|} log_2(-\frac{|C_i|}{\sum_{j=1}^{m} |C_j|}) \right]$$

- Dacă selectăm atributul A_i într-un nod, cantitatea necesară pentru a termina construcția arborelui este suma ponderată a conținutului de informație din toți subarborii generați pentru fiecare valoare a_v din domeniul lui A_i

$$E(A_i) = \sum_{k=1}^{v} \frac{|SI_{A_i=a_k}|}{|SI_{A_i}|} I(AD_{SI_{A_i=a_k}})$$

- Câștigul informațional obținut prin selecția unui atribut A_i ca rădăcină a arborelui de decizie este:
$$G(A_i) = I(AD_{SI_{A_i}}) - E(A_i)$$
- Pentru construcție, selectăm acel atribut A_i cu câștig informațional maxim: $\underset{A_i}{\operatorname{argmax}}\, G(A_i)$
- Arborele de decizie se construiește prin alegerea recursivă a unui atribut în fiecare nod de pe căile formate

Calculăm $G(Vreme)$, $G(Temperatură)$, $G(Umiditate)$ și $G(Vânt)$

- $G(Vreme) = I(AD_{SI}) - E(Vreme)$
- $I(AD_{SI}) = -\frac{9}{14} log_2 \frac{9}{14} - \frac{5}{14} log_2 \frac{5}{14} = \mathbf{0.94}$
- $E(Vreme{=}Soare) = -\frac{2}{5} log_2 \frac{2}{5} - \frac{3}{5} log_2 \frac{3}{5}$
- $E(Vreme{=}Nori) = -\frac{4}{4} log_2 \frac{4}{4} - \frac{0}{4} log_2 \frac{0}{4}$
- $E(Vreme{=}Ploaie) = -\frac{3}{5} log_2 \frac{3}{5} - \frac{2}{5} log_2 \frac{2}{5}$
- $E(Vreme) = \frac{5}{14} E(Vreme{=}Soare) + \frac{4}{14} E(Vreme{=}Nori) + \frac{5}{14} E(Vreme{=}Ploaie)$
- $E(Vreme) = \mathbf{0.694}$
- $G(Vreme) = \mathbf{0.94} - \mathbf{0.694} = \mathbf{0.246}$

Zi	Vreme	Temperatură	Umiditate	Vânt	Clasă
1	Soare	Cald	Mare	Fals	Nu
2	Soare	Cald	Mare	Adevărat	Nu
3	Nori	Cald	Mare	Fals	Da
4	Ploaie	Plăcut	Mare	Fals	Da
5	Ploaie	Răcoare	Normal	Fals	Da
6	Ploaie	Răcoare	Normal	Adevărat	Nu
7	Nori	Răcoare	Normal	Adevărat	Da
8	Soare	Plăcut	Mare	Fals	Nu
9	Soare	Răcoare	Normal	Fals	Da
10	Ploaie	Plăcut	Normal	Fals	Da
11	Soare	Plăcut	Normal	Adevărat	Da
12	Nori	Plăcut	Mare	Adevărat	Da
13	Nori	Cald	Normal	Fals	Da
14	Ploaie	Plăcut	Mare	Adevărat	Nu

Calculăm $G(Vreme)$, $G(Temperatură)$, $G(Umiditate)$ și $G(Vânt)$

- $G(Vreme) = \mathbf{0.246}$
- $G(Temperatură) = 0.029$
- $G(Umiditate) = 0.151$
- $G(Vânt) = 0.048$

Alegem cel mai informativ atribut, **Vreme**, pentru nodul rădăcină.

Zi	Vreme	Temperatură	Umiditate	Vânt	Clasă
1	Soare	Cald	Mare	Fals	Nu
2	Soare	Cald	Mare	Adevărat	Nu
3	Nori	Cald	Mare	Fals	Da
4	Ploaie	Plăcut	Mare	Fals	Da
5	Ploaie	Răcoare	Normal	Fals	Da
6	Ploaie	Răcoare	Normal	Adevărat	Nu
7	Nori	Răcoare	Normal	Adevărat	Da
8	Soare	Plăcut	Mare	Fals	Nu
9	Soare	Răcoare	Normal	Fals	Da
10	Ploaie	Plăcut	Normal	Fals	Da
11	Soare	Plăcut	Normal	Adevărat	Da
12	Nori	Plăcut	Mare	Adevărat	Da
13	Nori	Cald	Normal	Fals	Da
14	Ploaie	Plăcut	Mare	Adevărat	Nu

ID3(SI, A) – construiește arborele de decizie AD

1. **dacă** $SI = \emptyset$
2. **atunci întoarce** o frunză etichetată $\perp$ *sau Failure*
3. **dacă** $A = \emptyset$
4. **atunci întoarce** o frunză etichetată cu disjuncția tuturor C_k din SI
5. **dacă** toate exemplele din SI au aceeași clasă C_k
6. **atunci întoarce** o frunză etichetată C_k
7. Selectează atribut A_i din A (cf. câștig informațional maxim)
8. Creează un nod nou cu eticheta A_i
9. Șterge A_i din A
10. $m =$ cea mai frecventă clasă din SI
11. **pentru** fiecare valoare v a lui A_i
12. fie $SI_{A_i=v}$ mulțimea exemplelor din SI unde A_i are valoarea v
13. creează $nod_{A_i=v} = ID3(SI_{A_i=v}, A, m)$
14. adaugă $nod_{A_i=v}$ copil al nodului curent

Complexitatea algoritmului:

- $G(A_i)$ trebuie calculat pentru fiecare $A_i \in A$ la fiecare nod (exceptând frunzele)
- $G(A_i)$ depinde de frecvențele claselor C_k calculate pentru fiecare valoare v a lui A_i din partiția $SI_{A_i=v}$. Rezultă complexitate $O(|C| * |A|)$ per iterație.
- Complexitate ID3: $O(|C| * |A| * |AD|)$, unde $|AD|$ este numărul de noduri interne ale arborelui de decizie

Caz 1. Nu există exemple în $SI_{A_i=v}$ pentru care $A_i = v$ (exemple de învățare lipsă)

- ID3 va eticheta frunzele cu $\perp$ sau *Failure*
- Soluție: Generalizăm atribuind frunzei clasa cu cu cea mai mare frecvență de apariție în $SI_{A_i=v}$

Caz 2. Exemplele sunt afectate de zgomot

- Valorile pentru unele atribute din unele obiecte din *SI* sunt afectate de zgomot (conțin erori)
- Arborele de decizie va clasifica incorect obiecte din *SI*
- Probleme:
  - Se vor genera arbori de decizie cu complexitate mai mare decât este necesar
  - Atributele afectate devin inadecvate (vezi linia 2 din pseudocodul ID3)
- Modificări necesare pentru ID3:
  1. Trebuie să eliminăm atributele neinformative dar fără a scădea acuratețea arborelui de decizie.
  2. Trebuie să putem lucra cu atribute inadecvate. Vom produce o etichetă de clasă C_k chiar dacă obiectele din *SI* nu sunt din aceeași clasă.

Caz 2. Exemplele sunt afectate de zgomot

- Soluție eliminare atribute neinformative:
  - Impunem condiția $G(A_i) > \alpha$
  - α suficient de mare pentru a elimina atributele nerelevante
  - Dacă nu există zgomot, se vor elimina și atribute relevante (chiar dacă slab informative)
- Soluții posibile pentru tratarea atributelor inadecvate:
  1. Etichetăm frunza cu clasa C_k cea mai numeroasă din SI
  2. Etichetăm frunza cu probabilitatea de apartenență la o clasă (calculând frecvența clasei C_k în SI)

Caz 3. Valori necunoscute de atribute în *SI*

- Setul de date nu conține valori pentru atributul A_i din unele obiecte
- Soluții posibile:
  1. Atribuim în locul valorilor lipsă cea mai frecventă valoare v a atributului A_i
  2. Atribuim în locul valorilor lipsă valoarea v cu cea mai mare probabilitate din distribuția de probabilitate a valorilor atributului A_i în funcție de apartenența la clase:

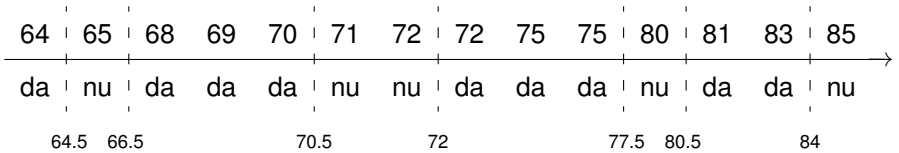
$$P(A_i|C_k) = \frac{P(A_i, C_k)}{P(C_k)}$$

Caz 3. Valori necunoscute de atribute în *SI*

- Setul de date nu conține valori pentru atributul A_i din unele obiecte
- Soluții posibile:
  3. Construim un arbore de decizie pe baza căruia să învățăm valorile lipsă ale lui A_i
     - Creăm un nou set de învățare folosind toate exemplele care au valori pentru A_i
     - Interschimbăm atributul A_i cu clasa (coloana atribut devina coloana clasă, iar clasa devine un atribut)
     - Construim un nou arbore de decizie bazat pe setul de învățare astfel format
     - Prezicem cu arborele învățat valoarea lui A_i din exemplele rămase (cele cu valori lipsă)

Caz 4. Atribute cu multe valori

- Atributul A_i are foarte multe valori
- Soluție posibilă pentru valori numerice:
  - Ordonăm toate valorile lui A_i
  - Selectăm „praguri de tăietură” între valorile unde se schimbă clasa
  - Discretizăm atributul A_i pe baza intervalelor găsite între pragurile de tăietură (fiecare interval devine o valoare)



Caz 4. Atribute cu multe valori

- Atributul A_i are foarte multe valori
- Soluție posibilă (1) pentru valori numerice:
  - Pentru fiecare valoare v a lui A_i împarte obiectele în $(-\infty, v]$ și $(v, +\infty)$
  - Pentru fiecare astfel de partiție calculează câștigul informațional și se selectează partiția cu câștig informațional maxim

Caz 4. Atribute cu multe valori

- Atributul A_i are foarte multe valori
- Soluție posibilă (2) pentru valori simbolice:
  - Utilizăm informația de separare care reprezintă cantitate de informație necesară pentru a determina valoarea v a unui atribut A_i într-un set de învățare Sl
  - Fie P_{Sl,A_i} distribuția de probabilitate peste toate cele m valori ale lui A_i.

$$P_{Sl,A_i} = (\frac{|A_i=v_1|}{|Sl|}, \frac{|A_i=v_2|}{|Sl|}, ..., \frac{|A_i=v_m|}{|Sl|})$$

  - Informația de separare se calculează conform:

$$ISep(A_i) = -\sum_{j=1}^{m} \frac{|A_i = v_j|}{|Sl|} log_2(\frac{|A_i = v_j|}{|Sl|})$$

Caz 4. Atribute cu multe valori

- Atributul A_i are foarte multe valori
- Soluție posibilă (2) pentru valori simbolice:
  - Utilizăm informația de separare care reprezintă cantitate de informație necesară pentru a determina valoarea v a unui atribut A_i într-un set de învățare SI
  - Definim rata de câștig a unui atribut $GR(A_i)$:

$$GR(A_i) = \frac{G(A_i)}{ISep(A_i)}$$

  - $GR(A_i)$ poate să nu fie întotdeauna definit (i.e. $ISep(A_i) = 0$) sau poate tinde să favorizeze valori mici pentru $ISep(A_i)$
  - Pentru a evita acest lucru, selectăm cel mai bun $GR(A_i)$ doar dintre atributele care au $G(A_i)$ mare (peste medie)

Păduri aleatoare

Ipoteză: combinăm mai multe modele de învățare pentru a crește acuratețea învățării

Bagging este un meta-algoritm prin care agregăm deciziile (independente) a mai multor astfel de modele

Păduri aleatoare (Random Forests) este un algoritm tip bagging unde pentru fiecare dintre cele K modele realizăm următorii pași:

- Selectăm aleator din SI o submulțime de obiecte (exemple)
- Selectăm aleator din A o submulțime de atribute
- Construim un arbori de decizie pe baza selecțiilor realizate

Păduri aleatoare

- Definim N este numărul total de exemple de învățare ($N = |SI|$) și M este numărul total de atribute ($M = |A|$)
- Se vor selecta aleator pentru construirea fiecărui arbore m atribute ($m < M$) din A și n exemple ($n < N$) din SI (eng. bootstrap samples)
- Restul exemplelor se folosesc pentru evaluare
- Fiecare arbore este construit complet plecând de la n și m

Păduri aleatoare

- La inferență, dându-se un exemplu pentru care nu cunoaștem clasa, fiecare arbore din pădurea aleatoare va aduce un vot (o clasă)
- Clasa finală se stabilește pe baza unui vot majoritar
- Avantajele pădurilor aleatoare (vs. ID3):
  - Acuratețe mai mare la învățare (în seturi de date cu separabilitate „complexă” a claselor)
  - Mai robust la zgomotele din setul de învățare
  - Prezintă încă tendințe de *overfitting* dar mult mai atenuate decât ID3

Păduri aleatoare

