Inteligență Artificială

IA aplicat în Prelucrarea Limbajului Natural

Slides: Alexandru Sorici, conținut parțial adaptat după slide-uri de la UMass (CS585) și ENSAE

- Intro
- Modele de Limbaj
- Task-uri tipice
- Scurt Istoric

Obiective:

- Descrierea **noțiunilor comune** folosite în Prelucrarea Limbajului Natural (eng. Natural Language Processing - NLP)
- Noțiuni principiale de **modelare a limbajului**
- Tipuri de probleme comune în NLP (e.g. parsare gramaticală, sumarizare, răspuns la întrebări, regăsirea de informații, identificarea entităților cu nume)

De ce ne interesează ca o IA să prelucreze limbaj natural?

De ce ne interesează ca o IA să prelucreze limbaj natural?

- Oamenii **comunică** prin limbaj

De ce ne interesează ca o IA să prelucreze limbaj natural?

- Oamenii **comunică** prin limbaj
- Oamenii **gândesc** (parțial) în limbaj

De ce ne interesează ca o IA să prelucreze limbaj natural?

- Oamenii **comunică** prin limbaj
- Oamenii **gândesc** (parțial) în limbaj
- Oamenii **spun povești** (care dau sens) în limbaj natural

De ce ne interesează ca o IA să prelucreze limbaj natural?

- Oamenii **comunică** prin limbaj
- Oamenii **gândesc** (parțial) în limbaj
- Oamenii **spun povești** (care dau sens) în limbaj natural
- Oamenii **construiesc teorii** în limbaj natural

De ce ne interesează ca o IA să prelucreze limbaj natural?

- Oamenii **comunică** prin limbaj
- Oamenii **gândesc** (parțial) în limbaj
- Oamenii **spun povești** (care dau sens) în limbaj natural
- Oamenii **construiesc teorii** în limbaj natural

Domeniul NLP e necesar pentru:

- Acces la cunoștințe (e.g. motor de căutare, sistem de recomandare, bază de cunoștințe)
- Comunicare om-om (traducere automată), om-mașină
- Acces la **raționamente umane**
- Explicabilitate

Definiții ale limbajului [Kracht, 2007]:

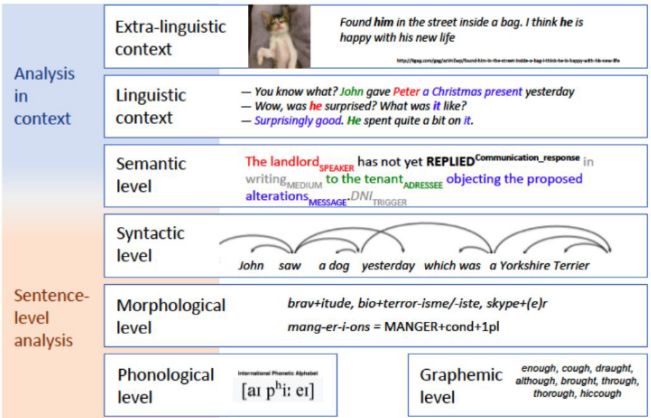
- Limbajul este o metodă de comunicare, un sistem **semiotic**. Prin aceasta se înțelege că este un set de semne. Un semn este o pereche constând într-un **semnificant** și un **semnificat**.

- Un **semn** constă într-o structură fonologică, o structură morfologică, o structură sintactică și o structură semantică.

Nivele de analiză lingvistică (de la simplu la compex):

- Fonetic
- Morfologic
- Nivel lexical
- Nivel sintactic
- Nivel semantic
- Nivel pragmatic
- Nivel al discursului (extra-lingvistic)

The Six Levels of Linguistics Analysis



cf. Sagot, Algorithms for speech and natural language processing, MVA course Material

Analiză morfologică – structura cuvintelor și formarea cuvintelor, componentele individuale ale cuvintelor:

- Morfem - Unitatea minimă de semnificație, prefix, rădăcină, sufix
- Prefix, Sufix – morfeme legate – necesită o rădăcină

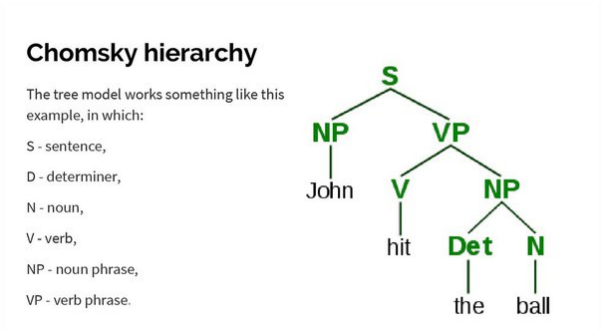
Analiză lexicală – sensul lexical și partea de vorbire (eng. part-of-speech):

- Utilizează lexicul unei limbi - colecție de lexeme / lexicon
- Lexem - o unitate de bază a sensului lexical, o unitate abstractă de analiză morfologică care reprezintă ansamblul formelor sau înțelesurilor luate de un singur morfem

- **Părți de vorbire (part-of-speech)**: etichetarea parțială a părților de vorbire (etichetare POS sau etichetare PoS sau POST), numită și etichetare gramaticală
- **Marcarea unui cuvânt** dintr-un text (corpus) ca fiind **corespunzător unei anumite părți de vorbire**, bazat atât pe **definiția sa**, cât și pe **contextul său**
- Părți de vorbire principale: substantiv, verb, articol, adjectiv, prepoziție, pronume, adverb, conjuncție și interjecție
- Există însă mult mai multe categorii și subcategorii, de exemplu plural sau singular, caz (rol ca subiect, obiect etc.), genul gramatical, etc.
- În unele sisteme de etichetare, diferite inflexiuni ale aceluiași cuvânt rădăcină vor obține părți diferite de vorbire, rezultând un număr mare de etichete

Analiza sintactică -– analiza părților sintactice ale frazei

- Bazată pe gramatica asociată limbajului, parsare
- Poate induce o ambiguitate sintactică



Exemplu de arbore de parsare sintactică, utilizând o ierarhie Chomsky a sintaxei pentru limba engleză.

Analiza semantică – Începe cu semantica lexicală - semnificațiile cuvintelor individuale (definițiile din dicționar).

- Apoi examinează relațiile dintre cuvintele individuale și analizează semnificația cuvintelor care se unesc pentru a forma o propoziție
- Ambiguitate semantică legată de sinonime sau de ambiguitatea sintactică

Analiza pragmatică — analiza părților sintactice ale **frazei**

- Evaluarea și înțelegerea mesajelor **în contextul comunicării umane**, având în vedere aspecte pragmatice și contextuale
- Modul în care limbajul este folosit în contextul real al comunicării
- **Intenția vorbitorului**
- **Contextul comunicării**
- Implicarea socială - aspecte sociale ale limbajului, cum ar fi normele culturale, relațiile interpersonale și regulile sociale care influențează comunicarea
- Conversația/ Discursul: Pragmatica în limbajul natural se ocupă și de analiza conversației, inclusiv a elementelor precum **schimbul de replici**, **structura discursului**, **rolurile participanților** și **modalitățile de gestionare a conversației**

- "Productivitatea" unui limbaj: faptul că o limbă se îmbogățește în timp cu sensuri, structuri și cuvinte noi (e.g. diferite neologisme, cuvinte împrumutate din alte limbi)
- **Ambiguitatea limbajului**
- **Factori de variabilitate și diversitate**
- **Distribuția naturală a cuvintelor în limbajul vorbit**

Ambiguitate la nivel lexical/semantic

- **Ambiguitate lexicală**
  - **Omonimie** – aceeași ortografie dar sensuri diferite (e.g. broască) – identitatea de formă a unor cuvinte cu sensuri diferite datorate originii diferite
- **Ambiguitate voită** (procedeu stilistic)
  - **Hiponimie** — relație între un termen generic și instanțele termenului generic (culoare / roșu, galben)
  - **Sinonimie** — forme lexicale diferite dar același sens sau sensuri apropiate (vulnerabil, firav, slab, nerezistent)
  - **Antinomie** — simetrie a înțelesului în funcție de o axă, de exemplu proprietate, utilizare etc. (agreabil / dezagreabil, adevărat / fals)

Ambiguitate la nivel lexical / semantică

- **Polisemie** – cuvinte cu sensuri diferite dar corelate – însușirea unui cuvânt de a avea mai multe sensuri în relație unul cu altul, deoarece provin dintr-un sens de bază. E.g.:
  - Cap ("Capul clanului Măcelaru este Tătuțu.")
  - Bancă ("Banca de întrebări a fost actualizată.")
- **Entități cu nume**: e.g. Michael Jordan este profesor la Berkley.

Ambiguitate sintactică: existența mai multor parsări *corecte* la nivel de arbore sintactic, dar cu înțeles diferit.

- Vând pat pentru copii cu picioare de lemn.
- Vând pat pentru copii cu picioare de lemn.

Ambiguitate pragmatică/de discurs

- Referențială – referire la obiecte anterioare (Tudor îl întreabă pe Mihai ce a făcut la examen. Mihai **i**-a spus că **l**-a luat.)
- Referire la loc, timp
- Ambiguități între semnificația uzuală și figurativă (Am o **tonă** de treabă.)
- Metonimie: a numi un obiect prin intermediul unui termen desemnând un alt obiect, legat cu primul printr-o relație logică (e.g. Bărbatul și-a *terminat* **farfuria**. Femeia *bea* un **pahar**.)
- Metaforă (figură de stil prin care se trece de la sensul obișnuit al unui cuvânt la alt sens, prin intermediul unei comparații subînțelese)

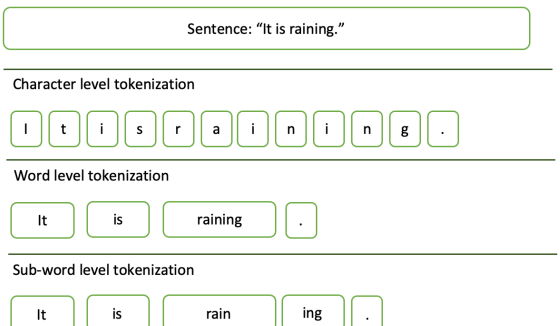
Diversitate

- La nivel de scriere (alfabet latin, grec, chirilic, arab; caractere chinezești japoneze, sanscrite, etc)
- Sintactică și morfologică: (e.g. ordinea cuvintelor în propoziție, existența articolului hotărât)
- La nivel lexical: e.g. texte scrise în ziar vs. mesaje scrise pe X (ex-Twitter)
- La nivel semantic / de context:
  - Cui ne adresăm (formal vs informal vs familial)
  - În ce perioadă (secol 19 vs secol 21)
  - Despre ce vorbim (masa de seară vs. cursul de IA)
  - ...
  - În general vom avea o variabilitate dată de: context social, geografie, sociologie, perioadă de timp, subiect de discuție, etc

- Cum organizăm texte sub forma unui set de date?
- Care sunt structurile cu care lucrăm?
- Ce pași tipici de pre-procesare putem aplica structurilor cu care lucrăm?

Definiții:

- Un **token** este o unitate discretă de date, definit a fi **un element dintr-un vocabular indexat** (e.g. $1, 2..., V$, unde $V = |vocabular|$)



- Token la nivel caracter – pro: simplu, con: parsare lungă
- Token la nivel cuvânt – pro: simplu de segmentat, con: cuvinte *în afara vocabularului*
- **Token la nivel sub-cuvânt** – cele mai frecvente cuvinte rămân intacte, iar cele rare sunt sparte în subsecvențe

Sursă imagine: On Tokenization in LLMs, Mina Ghashami, Medium

Definiții:

- Un **document** – o secvență de N cuvinte, notată ca $d = (w_1, w_2, \ldots w_N)$, w_i este al i-ulea cuvânt din secvență
- Un **document** poate fi (de exemplu):
  - O propoziție
  - Un paragraf
  - O secvență de caractere
  - Un articol într-un volum de lucrări științifice
- Un **corpus** – o colecție de **documente**, notată ca $D = (d_1, d_2, \ldots d_M)$. Exemple:
  - Wikipedia
  - Articole din presă de la G4Media pe anul 2023

Procesări pentru obținerea unităților de interes:

- **Segmentare a textului**:
  - Segmentare în **unități de modelare** (**documente**): e.g. în propoziții, paragrafe, pagină web, bloc de 1000 de caractere
  - **Tokenizare** – segmentarea documentelor în **unități de bază** (**tokeni**) la nivel cuvânt, sub-cuvânt, caracter

- *Opțional* pentru obținerea unui **vocabular**:
  - **Lematizare**: procedură de *restrângere* a unui cuvânt la forma sa *de dicționar* (**lemă**) – se reduc formele flexionare, conjugări (e.g. măr**ului** $\longrightarrow$ măr, căzuse $\longrightarrow$ a cădea)
  - **Stemming**: reducerea cuvintelor la *rădăcina* lor comună – ignorând sufixe pentru acorduri, declinări, conjugări (e.g. scriere, scriitor, scrisoare, scria $\longrightarrow$ scri)
    - Avantaj: ușor de implementat, util în proceduri de regăsire a informației
    - Dezvantaj: se pierd diferențe între tipuri gramaticale de cuvinte; ambiguitate între cuvinte neînrudite, dar cu aceeași rădăcină

Cum se modelează dependența unui cuvânt de altele dintr-un document?

- **Cu gramatici**: regulate, dependente de context, independente de context, independente de context și probabilistice
- **La nivel probabilistic**: se calculează **probabilitatea** unei propoziții înțeleasă ca **secvență de cuvinte**: $p(d) = p(w_1, w_2, \ldots w_n)$
  - Un obiectiv conex este modelarea probabilității de apariție a unui cuvânt următor $p(w_i|w_{i-1}, w_{i-2}, \ldots, w_1)$
  - Un model care calculează $p(d)$ sau $p(w_i|w_{i-1}, w_{i-2}, \ldots, w_1)$ se numește model de limbaj

Recapitulare Rețele Bayesiene:
Regula produsului de probabilități aplicată pe **probabilitatea comună** a *n* variabile aleatoare:

$$
\begin{aligned}
P(X_1, X_2, \ldots, X_n) &= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}, X_{n-2}, \ldots, X_1) \\
&= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1)P(X_{n-2}, \ldots, X_1) \\
&= P(X_n|X_{n-1}, X_{n-2}, \ldots, X_1)P(X_{n-1}|X_{n-2}, \ldots, X_1) \ldots P(X_1) = \prod_{i=1}^{n} P(X_i|X_{i-1} \ldots X_1)
\end{aligned}
$$

Aplicare pe cuvinte dintr-o propoziție:

$$p(w_1, w_2, \ldots, w_n) = \prod_{i=1}^{n} p(w_i | X_{w-1} \ldots w_1)$$

Exemplu:

- *p("vreau sa mănânc pește prăjit") = p("vreau") · p("să" | "vreau") · p("mănânc" | "vreau", "să") · p("pește" | "vreau", "să", "mănânc") · p("prăjit" | "vreau", "să", "mănânc", "pește")*

Cum estimăm aceste probabilități?

Cum estimăm aceste probabilități?

- Putem estima prin contorizare?
  - p("prăjit" | "vreau", "să", "mănânc", "pește") = $\frac{count(\text{"vreau să mănânc pește prăjit"})}{count(\text{"vreau să mănânc pește"})}$

Cum estimăm aceste probabilități?

- Putem estima prin contorizare?
  - p("prăjit" | "vreau", "să", "mănânc", "pește") = $\frac{count(\text{"vreau să mănânc pește prăjit"})}{count(\text{"vreau să mănânc pește"})}$
- **Nu.** Sunt prea multe propoziții posibile. Nu vom putea avea suficiente exemple într-un corpus, ca să estimăm orice frazare posibilă într-o limbă.

(O) **soluție**: aplicăm presupunerea simplificatoare Markov

- p("prăjit" | "vreau", "să", "mănânc", "pește") $\approx$ p("prăjit" | "pește")
- p("prăjit" | "vreau", "să", "mănânc", "pește") $\approx$ p("prăjit" | "mănânc", "pește")

Pe caz general, putem aproxima

$$p(w_i|w_1, w_2, \ldots, w_{i-1}) \approx p(w_i|w_{i-k}, \ldots, w_{i-1})$$

Model unigram

- Când $k = 0$, fiecare cuvânt este văzut **independent** de celelalte cuvinte din document (model **bag of words**)
  - p("vreau", "să", "mănânc", "pește", "prăjit") $\approx$ p("vreau") $\cdot$ p("să") $\cdot$ p("mănânc") $\cdot$ p("pește") $\cdot$ p("prăjit")

Modele n-gram

- Dependența Markov poate fi extinsă la $k = 1$ (bi-grame), $k = 2$ (tri-grame), 4-grame, 5-grame
- Modelele n-gram sunt adesea suficiente pentru nevoia de modelare a dependenței
- Dar **nu acoperă** toate cazurile. Exemplu:
  - **Mâncarea** pe care am pus-o în capătul mesei frumos aranjate **s-a răcit**.

Exemplu de estimare model **bi-gram**. Fie următorul corpus de propoziții:

- $< s >$ Eu sunt Alex $< /s >$
- $< s >$ Sunt înfometat $< /s >$
- $< s >$ Eu vreau pește prăjit $< /s >$

$$p(w_i|w_{i-1}) = \frac{p(w_{i-1}, w_i)}{p(w_{i-1})} \overset{\text{MLE}}{=} \frac{count(w_{i-1}, w_i)}{count(w_{i-1})}$$

$$p(\text{eu}|\text{<s>}) = \frac{2}{3} \quad p(\text{sunt}|\text{<s>}) = \frac{1}{3} \quad p(\text{sunt}|\text{eu}) = \frac{1}{2}$$

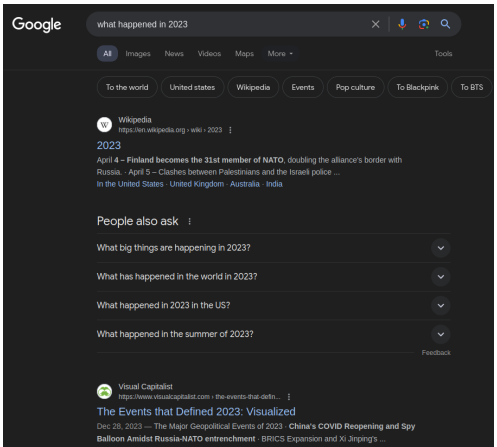
$$p(\text{infometat}|\ \text{sunt}) = \frac{1}{2} \quad p(\text{Alex}|\text{sunt}) = \frac{1}{2} \quad p(\text{</s>}|\text{Alex}) = \frac{1}{1}$$

$$p(\text{<s> Eu sunt Alex </s>}) = p(\text{eu}|\text{<s>}) \cdot p(\text{sunt}|\text{eu}) \cdot p(\text{Alex}|\text{sunt}) \cdot p(\text{</s>}|\text{Alex}) = \frac{2}{3} \cdot \frac{1}{2} \cdot \frac{1}{2} \cdot \frac{1}{1}$$

- Dându-se documente cu text, se cere clasificarea lor în:
  - Categorii semantice de subiect (e.g. sport, politică, economie)
  - Categorii de opinie / sentiment (e.g. pozitiv, negativ, neutru)




Google
ce s-a intamplat in 2023
All Images News Videos Maps More Tools
16 februarie – Parlamentarii ruși din Duma de Stat votează pentru retragerea Rusiei din 21 de convenții ale Consiliului Europei. Timișoara, Capitală Europeană a Culturii 2023 17 februarie: Timișoara devine Capitală Europeană a Culturii din partea României.
Wikipedia
https://ro.wikipedia.org › wiki › 2023
2023 - Wikipedia
About featured snippets • Feedback
Wikipedia
https://ro.wikipedia.org › wiki › 2... · Translate this page
2023 în România
Evenimente modificare · 1 ianuarie: Salariul minim brut crește de la 2.550 de lei la 3.000 de lei, în timp ce salariul minim din construcții crește la 4.000 de ...
YouTube · Profit Point
1.3K+ views · 4 months ago
Ce s-a întâmplat în 2023?
... 2023. De asemenea, nu ratați predicțiile lui Richard pentru 2024! Vă promitem o ... Ce s-a întâmplat în 2023? 1.3K views · 2 months ago ...


Google
what happened in 2023
All Images News Videos Maps More Tools
To the world United states Wikipedia Events Pop culture To Blackpink To BTS
Wikipedia
https://en.wikipedia.org › wiki › 2023
2023
April 4 – Finland becomes the 31st member of NATO, doubling the alliance's border with Russia. · April 5 – Clashes between Palestinians and the Israeli police ...
In the United States · United Kingdom · Australia · India
People also ask
What big things are happening in 2023?
What has happened in the world in 2023?
What happened in 2023 in the US?
What happened in the summer of 2023?
Feedback
Visual Capitalist
https://www.visualcapitalist.com › the-events-that-defin...
The Events that Defined 2023: Visualized
Dec 28, 2023 — The Major Geopolitical Events of 2023 · China's COVID Reopening and Spy Balloon Amidst Russia-NATO entrenchment · BRICS Expansion and Xi Jinping's ...

Obiectiv: etichetarea fiecărui cuvânt dintr-o propoziție cu **partea sa de vorbire** corespunzătoare.

[My , name, is, Bob, and, I, live, in, NY, !]

[PRON , NOUN, VERB, NOUN, CC, PRON, VERB, PREP, NOUN, PUNCT]

- **Detecția Intenției** este o problemă de **clasificare** a unei secvențe de cuvinte într-o categorie ce denotă **intenția utilizatorului**
- **Etichetarea slot-urilor** este o problemă **de etichetare** având ca scop identificarea unor **paremetrii** ai **intenției**

Can you please play Hello from Adele ?

Intent: ***play_music***
Slots: [*Can, you, please, play, Hello, from, Adele, ?]*
*[O , O , O , O , **SONG**, O , ARTIST, O]*

Recunoașterea Entităților (eng. Named Entity Recognition – **NER**)

- Sarcină de **etichetare a subsecvențelor** de cuvinte ca fiind o **entitate** (e.g. persoană, loc, nume de stat, nume de film, personaj politic, actor)

[My , name, is, Bob, and, I, live, in, NY, !]

*[O , O, O, **PERSON**, O, O, O, O, **LOCATION**, O]*

Task-uri tipice : Răspuns la întrebări

Extractive [SQuAD]

Question: At what speed did the turbine operate?
Context: (Nikola_Tesla) On his 50th birthday in 1906, Tesla demonstrated his 200 horsepower (150 kilowatts) 16,000 rpm bladeless turbine. ...
Gold answer: 16,000 rpm

Abstractive [NarrativeQA]

Question: What does a drink from narcissus's spring cause the drinker to do?
Context: Mercury has awakened Echo, who weeps for Narcissus, and states that a drink from Narcissus's spring causes the drinkers to "Grow dotingly enamored of themselves." ...
Gold answer: fall in love with themselves

Multiple-Choice [ARC-challenge]

Question: What does photosynthesis produce that helps plants grow?
Candidate Answers: (A) water (B) oxygen (C) protein (D) sugar
Gold answer: sugar

Yes/No [BoolQ]

Question: Was America the first country to have a president?
Context: (President) The first usage of the word president to denote the highest official in a government was during the Commonwealth of England ...
Gold answer: no

Sursa: Question Answering – innerdoc.com

Multe alte task-uri frecvent utilizate astăzi:

- Traducere automată
  - Specializare: traducere din limbaj natural în query SQL
- Sumarizare de text: extractivă, abstractivă
- Generare de text:
  - Cod software
  - Comentarii pentru cod software
  - Eseu

Scurt Istoric



1940-2000

Focus on rule-based systems, formal grammars

Development of linguistic resources (lexicon, ontologies, grammars...)

1990-2010

Statistical learning theory (SVM, Random Forest), Graphical Probabilistic Models (e.g. LDA, HMM)

Development of annotated datasets

2010-Today

Deep Learning Architecture (Transformer)

Transfer Learning in NLP (word2vec, BERT, CamemBERT, GPT)

More compute, larger (raw) dataset, Open Source Deep Learning Libraries

Cursul următor:

- Cum transformăm text în valori numerice (vectori de numere), astfel încât să putem:
  - Să calculăm grade de similaritate / dependență / înrudire semantică prin metode numeric?
  - Să utilizăm algoritmi de învățare (e.g. rețele neurale) pe input text

- Cum funcționează principial și cum pot fi utilizate Modelele Mari de Limbaj (LLM)?

Mulțumesc!



Feedbackul este binevenit!

Kracht, M. (2007).
Introduction to linguistics.
Los Angeles. LA: Hilgard Avenue, 2.